

基于组内相对评分的题目行为机制诊断与迁移方案

基于组内相对评分的题目行为机制诊断与迁移方案

当前建议实施顺序是：

- 1. 22A-2 真实单题观察器
- 2. 04_Memory系统实施计划.md 的候选抽取与全局记忆沉淀
- 3. 05_Global_Judge与自进化治理实施计划.md
- 4. 06_审计回放与运行治理实施计划.md
- 5. 22B-2 机制候选归纳
- 6. 22B-3 机制效果验证
- 7. 25B + 22C-4 路由旁路验证与有限接入

状态：22A-0 已完成，22A-1 规则式旁路诊断已落地；真实单题观察器作为 22A-2 待实施
修订日期：2026-08-07

读者：负责评分、样本画像、算子路由、题目生成、实验复盘和人工审核的内部工程人员

1. 方案定位

当前流水线已经可以完成以下主流程：

代码块

- 1 题目评分
- 2 -> 样本画像
- 3 -> 选择题目进化算子
- 4 -> 生成新题
- 5 -> 校验新题
- 6 -> 再次评分
- 7 -> 比较父题和子题分数
- 8 -> 记录边界候选和实验结果

这个流程能回答“用了哪个算子后分数有没有下降”，但还不能稳定回答：

- 1. 分数低是模型真的不会，还是题目、参考答案、评分标准或评分模型有问题；

- 2. 同一道题的多个回答为什么有高有低；
- 3. 子题降分是算子压中了目标能力，还是引入了歧义、格式负担或不可回答内容；
- 4. 单题里观察到的失败原因，能否整理成跨题复用的机制。

本方案要补的是一层**题目行为机制诊断**。它不替代现有评分、画像、路由和题目生成，也不直接改变 `score_rate`、算子选择、搜索状态或正式记忆。它先把多次回答和多次评分的差异整理成可复查证据，再决定哪些证据可以沉淀为跨题复用的机制。

为了避免和全局记忆方案重复，本文把实施拆成三段：

- **统计与规则诊断层**：先在本方案中实现，产出题目级旁路诊断文件；
- **真实单题观察层**：在规则诊断筛出的合格题上调用 LMM 观察器，生成语义解释；
- **机制沉淀层**：接入 25 号方案的全局记忆体系，不另建一套长期机制库。

2. 实施顺序总览

本方案不应完整排在 25 号方案之后，也不应完整排在 25 号方案之前。推荐顺序如下。

顺序	阶段	归属方案	目标	是否影响主流程
1	22A-0	本方案	离线统计多回答和多评分差异	否
2	22A-1	本方案	生成题目行为旁路文件，使用规则式诊断和证据校验	否
3	22A-2	本方案	对合格题调用真实单题观察器，生成 LMM 语义分析	否
4	25A	25 号方案	建立全局记忆的分类、卡片、快照和只审计读取能力	否
5	22B-2	本方案接入 25	从旁路诊断和观察器结果中归纳机制候选，写入 25 的发布流程	否
6	22B-3	本方案接入 25	建立机制效果矩阵，验证机制和算子的关系	否
7	25B + 22C-4	两个方案共同完成	只做路由旁路对照，验证后才考虑有限接入	默认否

2.1 为什么先做 22A

22A 负责回答“这道题内部的回答差异是否可靠”。其中 22A-0 和 22A-1 先用确定性统计和规则式旁路诊断完成证据整理；22A-2 再对少量合格题调用真实单题观察器。

如果没有 22A 的证据，25 号全局记忆只能主要依赖现有的成功、失败和无效生成记录，容易只知道“发生了什么”，但不知道“为什么发生”。

2.2 为什么 22A-2 要放在 22B 前

22B 要归纳跨题机制，不能只依赖单题分数现象。22A-2 的真实观察器负责把高低回答差异、评分标准项和题目风险转成可复查解释，作为机制候选的高质量输入。

如果 22A-2 暂未实施，也可以先让 22B 读取 22A-1 的规则式旁路结果，但只能生成低置信机制候选，不能升级为 `qualified`。

2.3 为什么机制沉淀要接入 25

25 号方案已经定义全局记忆要保存：

代码块

```
1  场景类型 × 题型结构 × 推理机制或虚高机制 × 算子策略
```

本方案的机制卡本质上就是全局记忆卡的一种来源。因此，本方案不再单独建立长期机制注册表。机制候选、机制效果矩阵和路由旁路建议，都应进入 25 号方案定义的全局记忆发布、快照和审计流程。

3. 当前真实数据基础

当前评分产物已经支持多回答和多次评分。每条完成评分的记录通常包含：

代码块

```
1  scoring_result.answer_trials
2  每个回答试次里有 candidate_answer
3  每个回答试次里有 qwen_judge_results
4  每个回答试次里有 qwen_score_rate_mean
5  可选 gpt_judge_results
6  可选 gpt_score_rate_mean
7  scoring_result.qwen_score_summary
8  scoring_result.gpt_score_summary
9  scoring_result.representative_trial_index
10 score_rate
```

首版必须继承以下边界：

1. `score_rate` 只由 Qwen 决策评分生成；
2. `scoring_result.qwen_score_summary.mean` 是当前主流程的分数来源；

- 3. GPT 评分只作为实验复评，用于离线对照，不能和 Qwen 分数平均；
- 4. GPT 评分缺失、失败或仍在等待时，不能阻断已经完成的 Qwen 决策评分；
- 5. 透传样本 `question_evolved == false` 不应重复生成回答或重新评分；
- 6. 后续画像、效果分析、状态更新和本地记忆写入，都不得读取 GPT 汇总来做正式决策。

4. 核心原则

4.1 分数现象不是原因

低分、高低回答分裂、拒答、分数波动，都只是表面现象。它们可能来自不同原因：

表面现象或风险	简单解释	默认处理
真实能力边界	多个回答稳定漏掉同一关键推理	可进入机制候选
题目形式负担	题目形式让模型容易失误，但不一定代表不会	只做观察和人工确认
题面质量风险	题目缺信息、有歧义、事实冲突或不可回答	不进入能力机制
评分标准风险	评分标准过度依赖固定措辞、扣分项过重或参考答案不稳定	进入评分治理
评分模型不稳定	同一回答被重复评分时分差过大	不做能力归因
不同评分模型分歧	Qwen 和 GPT 对高低方向判断相反	不做强结论
拒答	可能是安全、信息不足、格式要求或任务不支持	先分类，不默认是能力问题

4.2 先用规则筛选，再让大模型解释

大模型不能在全量样本上自由解释原因。必须先用确定性规则判断：

- 1. 回答和评分是否完整；
- 2. 同一回答的重复评分是否稳定；
- 3. 不同回答的分数差是否足够明显；
- 4. 分差能否对应到具体评分标准项；
- 5. 题目、参考答案和评分标准是否完整。

只有通过这些检查的题，才可以进入 22A-1 规则式旁路诊断。22A-1 输出合格且证据完整的题，才可以进入 22A-2 真实单题观察器。

4.3 任何旁路诊断不得直接改主流程

在完成独立验证前，本方案产物不得修改：

- `score_rate` ;
- `scoring_result` ;
- `sample_profile` ;
- `overscore_diagnosis` ;
- `operator_route.operator_candidates` ;
- `evolution_state` ;
- `memory/*.jsonl` ;
- 已冻结的 `operator_plan` 或搜索状态。

5. 组内统计方法

同一道题的多个回答构成一个组。先看每个回答自己的重复评分，再比较不同回答。

5.1 回答级统计

对每个回答计算：

代码块

```
1  qwen_score_rate_mean
2  qwen_score_min
3  qwen_score_max
4  qwen_score_range
5  relative_advantage
6  relative_class
7  gpt_score_rate_mean
8  cross_judge_gap
```

其中：

代码块

```
1  group_mean = mean(所有回答的 qwen_score_rate_mean)
2  relative_advantage = qwen_score_rate_mean - group_mean
```

`relative_advantage` 只用于排序和描述，不能作为训练奖励，也不能直接进入正式路由。

5.2 同一回答的评分差异

同一个回答被多次评分后，如果分数不同，也要分析原因。它回答的问题不是“这个回答比同题其他回答强还是弱”，而是“评分本身是否稳定”。

对每个回答先计算：

代码块

```
1 qwen_score_min = 同一回答多次 Qwen 评分的最低分
2 qwen_score_max = 同一回答多次 Qwen 评分的最高分
3 qwen_score_range = qwen_score_max - qwen_score_min
```

如果 `qwen_score_range` 很小，说明评分比较稳定，可以使用 `qwen_score_rate_mean` 代表这个回答。

如果 `qwen_score_range` 超过 `MAX_WITHIN_ANSWER_JUDGE_RANGE`，这道题先标记为 `judge_unstable`，不能继续推出“模型能力机制”。此时应优先检查：

1. 评分标准是否写得太模糊；
2. 参考答案是否只覆盖了一种说法；
3. 回答是否处在“可给分也可扣分”的边界；
4. 扣分项是否被不同评分重复触发得不一致；
5. 评分模型是否对同一段文字判断不稳定。

这类差异可以进入评分治理或人工复核，但不能直接说成模型能力问题。只有同一回答的重复评分稳定后，才比较不同回答之间的高低差异。

5.3 首版建议阈值

以下阈值只作为首版默认值。22A-0 必须用真实实验数据校准，校准后再冻结。

配置名	建议默认值	含义
MIN_VALID_TRIALS	3	每题至少需要的有效回答数
MIN_QWEN_REPEATS_PER_TRIAL	2	每个回答至少需要的 Qwen 重复评分数
ABSOLUTE_ANSWER_GAP	0.1	高低回答均分至少差多少才值得分析
MAX_WITHIN_ANSWER_JUDGE_RANGE	0.05	同一回答重复评分允许的最大分差
STRICT_SEPARATION_REQUIRED	FALSE	是否要求高分回答最低分仍高于低分回答最高分
CROSS_JUDGE_DIRECTION_GAP	0.1	Qwen 和 GPT 方向冲突的观察阈值

如果 GPT 结果还没有完成，不能生成强 `cross_judge_disputed` 结论，只能记录 `gpt_incomplete`。

6. 评分标准项级统计

只看总分不够。必须知道高低回答到底差在哪条评分标准上。

6.1 评分标准对齐

评分标准项必须按标题对齐：

- 1. 每条评分标准的 `title` 必须非空；
- 2. 同一套评分标准内 `title` 必须唯一；
- 3. 评分结果中的每个 `item_scores.title` 必须能对应到原始评分标准；
- 4. 标题无法对应时，该条评分不能进入强诊断。

6.2 正权重项

正权重项表示加分项：

代码块

```
1 positive_award_ratio = awarded / weight
```

它用于判断某个回答是否稳定命中或稳定漏掉某条要求。

6.3 负权重项

负权重项表示扣分项，不能当普通加分项处理：

代码块

```
1 penalty_activation = abs(awarded) / abs(weight)
```

0 表示没有触发扣分， 1 表示完全触发该扣分项。高低回答如果主要差在扣分项上，必须单独标记，不能简单说是能力机制。

6.4 零权重项

weight == 0 的项只作为观察项，不进入得分率和难度归因。它可以辅助解释，但不能单独支撑机制结论。

7. 题目级标签

每道题至少生成一个题目级标签。多个标签可以并存，但必须有优先级。

标签	触发条件	后续动作
insufficient_trials	回答数或评分数不足	只记录，不进入 22A-2
judge_unstable	同一回答的 Qwen 重复评分差过大	不做能力归因
cross_judge_disputed	GPT 完整且与 Qwen 高低方向明显相反	不做强机制结论
rubric_or_question_risk	分差无法对应到稳定评分标准项，或题目/参考答案存在风险	优先人工检查
near_group	回答之间分差不足	只保留统计
uniformly_easy	组均值高、回答差距小、评分稳定	不进入 22A-2
uniformly_hard	组均值低、多个回答稳定漏掉同类要求	可做稳定失败诊断
informative_answer_gap	高低回答差距明显、评分稳定、评分标准差异可定位	可进入 22A-2

优先级建议：

代码块

```
1 insufficient_trials
2     -> judge_unstable
3     -> cross_judge_disputed
4     -> rubric_or_question_risk
5     -> informative_answer_gap / uniformly_hard / uniformly_easy / near_group
```

`uniformly_hard` 不应强行走高低回答对比。它可以进入“稳定失败诊断”，重点看多个低分回答是否稳定漏掉同一类要求。

8. 真实单题观察器（22A-2）

22A-1 的规则式旁路诊断只负责统计、打标签、写 `behavior_analysis.jsonl` 和校验证据。真实单题观察器属于 22A-2，它在 22A-1 筛出的少量合格题上调用 LMM 做语义解释。

真实单题观察器的任务是解释：

代码块

```
1  高分回答做对了什么
2  低分回答漏掉了什么
3  这些差异能不能对应到具体评分标准项
4  这是不是能力机制，还是题目、评分标准或评分风险
```

8.1 调用条件

只有满足以下条件时才调用真实单题观察器：

1. 题目标签包含 `informative_answer_gap`，或明确进入 `uniformly_hard` 稳定失败诊断；
2. Qwen 重复评分稳定；
3. GPT 完整时没有明显反向分歧；
4. 高低差异能定位到正权重项或扣分项；
5. 当前题目、参考答案、评分标准和评分配置完整；
6. 相同内容指纹和分析版本没有分析过。

每个题目版本最多调用一次。失败、超时或返回格式错误时，只记录失败状态，不发布半成品结论。未实施 22A-2 时，22A-1 只能输出规则式诊断，不得伪造 LMM 观察结论。

8.2 输入限制

为了避免大模型复述已有结论，第一次观察只允许读取：

- 当前题目；
- 参考答案；
- 评分标准；
- 选中的高分回答、低分回答和可选近均值回答；
- 统计后的评分标准项得分；
- 回答试次编号、评分标准项编号和回答片段编号。

第一次观察不允许读取：

- `sample_profile`；
- `overscore_diagnosis`；
- 历史算子；
- `expected_qwen_failure`；
- 评分模型的自然语言理由；
- 搜索终态；
- 任何记忆命中。

画像和历史字段只能在观察完成后，用于离线分组和复盘。

8.3 输出要求

输出必须是合法 JSON，建议使用新增结构约束文件：

代码块

```
1 schemas/question_behavior_analysis.schema.json
```

每条输出至少包含：

代码块

```
1 {"analysis_status": "completed", "behavior_labels":  
  ["informative_answer_gap"], "difference_summary": "", "high_answer_strengths":  
  [], "low_answer_failures": [], "rubric_evidence": [], "candidate_mechanisms":  
  [], "question_or_rubric_risk": null, "confidence": "low"}
```

每个结论必须引用具体证据：

- 哪个 `trial_index`；

- 哪条评分标准 `title` ；
- 哪段回答文本；
- 如果使用扣分项，必须说明对应的扣分项。

没有证据时只能输出 `unknown` 。不能用“推理不够深入”“理解不充分”这类空话代替证据。

9. 旁路文件

旁路文件是独立诊断记录，不直接写回主评分记录。建议文件名：

代码块

```
1 behavior_analysis.jsonl
```

每条记录至少包含：

代码块

```
1 {"analysis_id": "", "root_sample_id": "", "node_id": "", "prompt_fingerprint":
  "", "rubric_fingerprint": "", "evaluation_config_fingerprint":
  "", "source_trial_ids": [], "group_statistics": {}, "behavior_labels":
  [], "observer_result": {}, "analysis_status": "shadow", "analysis_version":
  "question-behavior-v1", "created_at": 0}
```

9.1 内容指纹

内容指纹用于判断旧分析是否还能使用：

指纹	来源
prompt_fingerprint	当前题目文本
rubric_fingerprint	当前评分标准的规范化内容
evaluation_config_fingerprint	回答模型、评分模型、回答次数、评分次数、关键阈值
analysis_version	本方案分析逻辑版本

任一指纹变化，旧旁路记录自动视为 `stale` 。

9.2 幂等写入

恢复运行时不能重复写同一条分析。建议幂等键：

代码块

```
1 analysis_version
2 + root_sample_id
3 + node_id
4 + prompt_fingerprint
5 + rubric_fingerprint
6 + evaluation_config_fingerprint
```

如果使用现有发布工具，应把 `behavior_analysis.jsonl` 登记到清单文件，和现有追踪旁路文件一样校验文件哈希。

9.3 父子题边界

父题分析不能直接复制给子题。子题题面、评分标准、参考答案或评分配置只要变化，就必须重新判断。父题诊断最多只能作为人工复盘背景，不能作为子题当前机制证据。

10. 机制卡和 25 号方案的关系

机制卡描述“跨多道题都能复现的失败原因”。它不是单题备注，也不是一次大模型解释。

本方案不单独建立长期机制库。机制候选应作为 25 号全局记忆发布流程的输入。对应关系如下：

本方案产物	25 号方案中的位置
单题旁路诊断	全局发布候选的证据来源
候选机制	reasoning_mechanism 的候选
题型结构	question_form
场景族	scene_family
风险标签	risk_labels
机制卡	全局记忆卡的一种
机制效果矩阵	全局记忆发布报告和回放评估的一部分

10.1 机制卡状态

机制卡状态建议沿用：

代码块

```
1 proposed -> shadow -> qualified -> production
2           -> rejected
3           -> retired
```

状态含义：

状态	含义	是否能影响正式路由
proposed	大模型或人工提出的候选机制	否
shadow	有初步证据，只做旁路观察	否
qualified	通过跨样本和人工复核，可进入受控实验	只限实验
production	经过独立验证，可有限参与正式策略	是，但必须可回滚
rejected	被证明不成立	否
retired	曾经有效，但当前版本不再适用	否

10.2 发布前校验

机制卡从 `proposed` 升级到 `shadow` 或更高状态前，必须通过：

- 1. 来自多个不同 `root_sample_id` 的证据；
- 2. 至少覆盖一个以上场景或题型，除非明确标为局部机制；
- 3. 人工确认不是题面质量问题；
- 4. 人工确认不是评分标准固定措辞问题；
- 5. 人工确认不是评分模型不稳定；
- 6. 关联算子必须来自当前算子注册表；
- 7. 记录版本、适用条件、排除条件和反例。

评分标准风险、题面风险、评分模型不稳定，只能发布为风险卡或治理信号，不能发布为能力机制卡。

11. 机制效果矩阵

机制效果矩阵回答：

代码块

- 1 某个机制 × 某个算子 × 某种题型 × 某类场景
- 2 到底有没有稳定效果

建议维度：

代码块

- 1 mechanism_id
- 2 operator_id
- 3 question_form
- 4 scene_family
- 5 version_compatibility_group

建议指标：

指标	含义
样本数	有多少条独立原始样本
适用率	多少题符合机制适用条件
成题率	算子生成后通过校验的比例
稳定降分率	分数下降且超过回答和评分波动的比例
目标机制命中率	子题低分是否真的命中该机制
回答方差	同题多个回答分数差异
评分分歧率	Qwen 内部或 Qwen/GPT 是否分歧
题面/评分标准风险率	多少结果可能不是能力问题
人工确认率	人工审核确认的比例
单个确认边界成本	得到一个确认边界需要多少调用和样本

样本不足时只能展示统计，不得提升算子优先级。

12. 与路由和记忆的接入边界

12.1 路由旁路对照

当前路由已经有 `operator_decision_audit`，用于记录选择、排除和不确定原因。机制诊断接入路由时，首版只允许写入审计信息或独立旁路文件。

不得做以下事情：

- 不得把机制建议追加进 `operator_candidates`；
- 不得因为机制建议删除路由器返回的合法候选；
- 不得用机制建议重排已冻结的 `operator_plan`；
- 不得让机制建议绕过算子硬槽位检查；
- 不得让机制建议绕过题目可回答性和质量校验。

12.2 记忆写入边界

本地 `memory/*.jsonl` 目前记录的是实验事实，例如有效边界、失败经验和无效生成。22A 阶段不能写正式记忆。

只有满足以下条件后，机制相关结果才可以进入 25 号全局记忆发布流程：

1. 已有旁路诊断证据；
2. 通过机制卡发布校验；
3. 通过人工复核；
4. 与 25 号分类体系对齐；
5. 有固定快照和可回放记录；
6. 不使用来源实验自证上线效果。

13. 详细实施阶段

13.1 22A-0：离线统计

目标：先回答“当前数据里有多少题真的有可解释的组内差异”。

输入：

- 已完成评分的 JSONL；
- `scoring_result.answer_trials`；
- 当前评分标准；
- 当前评分配置。

产物：

- 离线统计报告；
- 每题题目级标签；

- 阈值校准建议；
- 不进入后续阶段的原因分布。

退出条件：

1. 能统计有效回答试次覆盖率；
2. 能统计 Qwen 重复评分稳定性；
3. 能统计回答间分差；
4. 能统计 Qwen/GPT 分歧；
5. 能统计正权重、负权重和零权重项；
6. 明确 `informative_answer_gap` 的覆盖率；
7. 如果覆盖率过低，停止在离线报告，不进入 22A-1 或 22A-2。

13.2 22A-1：规则式旁路诊断和证据文件

目标： 对合格题生成可复查的规则式旁路诊断，不调用 LMM，不做自由解释。

当前工程状态： 已落地。实现内容包括离线统计输入、规则式标签、`behavior_analysis.jsonl` 旁路文件、幂等写入、内容指纹过期判断、schema 约束和证据引用校验。

产物：

- `behavior_analysis.jsonl`；
- 规则式题目标签；
- 统计摘要和证据引用；
- 失败、跳过和过期记录；
- 人工抽检样本。

退出条件：

1. 旁路记录符合 `question_behavior_analysis.schema.json`；
2. 重复运行不会写入重复记录；
3. 题目、评分标准或评分配置指纹变化后，旧记录会过期；
4. 证据引用能定位到回答试次、评分标准和统计结果；
5. 关闭开关后主流程输出完全不变。

13.3 22A-2：真实单题观察器

目标： 在 22A-1 筛出的少量合格题上调用真实单题观察器，让 LMM 解释高低回答差异、评分标准命中差异和题目风险。

输入：

- 22A-1 生成的合格 `behavior_analysis.jsonl` 记录；
- 当前题目、参考答案和评分标准；
- 选中的高分回答、低分回答和可选近均值回答；
- 评分标准项级统计；
- 内容指纹和分析版本。

产物：

- 真实观察器调用记录；
- LMM 语义分析结果；
- 观察器失败、超时和格式错误记录；
- 人工抽检样本。

退出条件：

1. 真实观察器只处理 `informative_answer_gap` 或明确进入稳定失败诊断的题；
2. 结构化输出解析成功率达到预先冻结阈值；
3. 中高置信结论大多能定位到回答试次、评分标准和文本证据；
4. 泛化空话比例低；
5. 人工复核认为诊断不是简单复述评分模型理由；
6. 失败、超时或格式错误不会写入半成品机制结论；
7. 关闭开关后主流程输出完全不变。

13.4 25A：全局记忆基础层

目标： 建立机制沉淀的公共底座。

本阶段属于 25 号方案，至少需要：

- 分类体系映射；
- 全局记忆卡结构文件；
- 发布候选结构文件；
- 运行时快照；
- 只审计检索；
- 发布报告。

没有 25A，本方案不应实现长期机制库。

13.5 22B-2：机制候选归纳

目标： 从多个旁路诊断和真实观察器结果中归纳候选机制。

输入：

- 已通过校验的 `behavior_analysis.jsonl` ；
- 22A-2 的真实观察器结果，如果已实施；
- 人工复核结果；
- 25A 的分类体系映射。

产物：

- `proposed` 机制卡候选；
- 反例列表；
- 风险标签；
- 进入 25 号发布流程的候选事实。

退出条件：

1. 每个机制候选都有多个独立样本证据；
2. 不把评分标准风险、题面风险或评分风险误发布为能力机制；
3. 每个机制都有适用条件和排除条件；
4. 每个机制都有可复查证据和反例。

13.6 22B-3：机制效果验证

目标： 验证机制和算子之间的关系。

实验分两类：

实验	回答的问题
固定算子实验	这个算子对哪些机制有效
固定机制实验	这个机制用哪些算子更容易稳定命中

必须冻结：

- 题目池；
- 作答模型；
- 作答参数；
- Qwen 评分配置；
- GPT 实验复评配置；

- 评分标准；
- 记忆快照；
- 阈值；
- 人工复核规则。

退出条件：

1. 分数变化超过回答和评分波动；
2. 子题低分命中目标机制；
3. 子题高分回答仍能通过正确推理拿高分；
4. 新失分不是题面歧义、不可回答、格式负担或评分标准漂移；
5. 机制能在独立原始样本上复现。

13.7 25B + 22C-4：路由旁路验证和有限接入

目标： 只在已有充分证据后，验证机制提示是否能帮助路由。

首版只允许：

- 写入路由审计；
- 写入单独旁路文件；
- 比较机制建议和现有路由结果；
- 在独立验证集上回放验证。

只有满足以下条件后，才可以讨论有限接入：

1. 25 号全局记忆快照稳定；
2. 机制卡至少达到 `qualified` ；
3. 独立验证集有稳定收益；
4. 没有增加明显的无效生成和分数升高；
5. 有开关、回滚和人工审核入口。

14. 校验规则清单

14.1 输入完整性校验

- `scoring_result` 必须存在；
- `decision_evaluation_status` 必须是 `completed` ；
- `answer_trials` 必须是非空数组；
- 有效回答数必须达到 `MIN_VALID_TRIALS` ；

- 每个回答必须有 `trial_index`、`candidate_answer`、`qwen_judge_results`、`qwen_score_rate_mean`；
- Qwen 分数必须在 0 到 1 之间；
- GPT 结果只在完整且有效时参与分歧观察。

14.2 评分稳定性校验

- 每个回答必须先计算 `qwen_score_min`、`qwen_score_max` 和 `qwen_score_range`；
- 同一回答内 Qwen 重复评分分差过大，标记 `judge_unstable`；
- 同一回答内评分差异过大时，必须保留最高分、最低分和对应评分结果，方便人工复查；
- 同一回答内评分差异过大时，优先检查评分标准、参考答案、扣分项和回答边界，不得直接归因为能力机制；
- 高低回答差距不足，标记 `near_group`；
- GPT 完整且方向相反，标记 `cross_judge_disputed`；
- 评分不稳定时，不得输出强机制结论。

14.3 评分标准校验

- 评分标准标题必须唯一；
- 评分项必须能对应到评分标准；
- 正权重、负权重、零权重必须分开统计；
- 真实观察器引用的评分标准项必须真实存在；
- 扣分项触发时必须单独说明。

14.4 真实观察器输出校验

本节只适用于 22A-2。22A-1 的规则式旁路诊断只需要通过旁路文件校验和证据引用校验。

- 输出必须是合法 JSON；
- 必须符合 `question_behavior_analysis.schema.json`；
- 每条结论必须能回查到回答试次、评分标准或回答片段；
- 没证据只能写 `unknown`；
- `confidence` 只能是 `low`、`medium` 或 `high`；
- `medium` 和 `high` 必须有可定位证据。

14.5 旁路文件校验

- 必须包含题目身份、节点身份、内容指纹、统计摘要、标签、版本和时间；

- 内容指纹变化后旧记录自动过期；
- 恢复运行不能重复写入；
- 父题记录不能直接当成子题记录；
- 旁路文件如果登记到清单文件，必须通过文件哈希校验。

14.6 机制卡校验

- 单题诊断不能直接升级为正式机制；
- 机制必须有跨样本证据；
- 机制必须有反例和排除条件；
- 风险类问题不能发布为能力机制；
- 关联算子必须来自当前算子注册表；
- 状态流转必须可追踪、可回退。

14.7 主流程隔离校验

- 不改 `score_rate`；
- 不改 `operator_candidates`；
- 不改 `evolution_state`；
- 不写正式记忆；
- 不改已冻结搜索计划；
- 旁路关闭后，主流程结果必须完全一致。

15. 测试要求

22A-0 和 22A-1 至少增加以下测试：

1. 回答试次顺序变化不影响组内统计；
2. 同一回答的 `qwen_score_min`、`qwen_score_max` 和 `qwen_score_range` 计算正确；
3. Qwen 重复评分分差过大时生成 `judge_unstable`；
4. `judge_unstable` 题目不会调用真实观察器生成能力机制结论；
5. 高低回答差距不足时生成 `near_group`；
6. GPT 结果缺失时不生成强 `cross_judge_disputed`；
7. Qwen/GPT 完整且方向相反时生成 `cross_judge_disputed`；
8. 正权重项比例计算正确；
9. 负权重扣分触发计算正确；

10. 零权重项不进入得分率归因；
11. 评分标准标题无法对齐时拒绝强诊断；
12. 未通过资格检查时不调用真实观察器；
13. 内容指纹变化后旧旁路记录过期；
14. 恢复运行不会重复写旁路记录；
15. 旁路诊断不会修改 `score_rate`、`scoring_result`、`operator_route`、`evolution_state` 或正式记忆；
16. 机制卡不能由单题诊断直接发布为 `qualified`。

22A-2 实施后追加以下测试：

1. 真实观察器输出证据引用不存在时拒绝发布；
2. 真实观察器失败、超时或格式错误时不会写入半成品机制结论；
3. 未启用 22A-2 时，22A-1 不会伪造 LMM 观察结论。

16. 验收指标

每次实验前必须冻结主指标、样本划分、阈值、排除条件、评分配置和人工复核规则。

建议指标：

1. 有效回答试次覆盖率；
2. `informative_answer_gap` 覆盖率；
3. `judge_unstable` 比例；
4. `cross_judge_disputed` 比例；
5. 可定位评分标准差异比例；
6. 真实单题观察器 JSON 解析成功率；
7. 中高置信结论的证据可定位率；
8. 泛化空话比例；
9. 人工复核一致率；
10. 跨原始样本机制复现率；
11. 机制到目标错误的命中率；
12. 机制效果矩阵中的稳定降分率；
13. 题面/评分标准风险率；
14. 单个已确认边界成本；
15. 路由旁路建议在独立验证集上的收益。

其中第 6、7、8 项主要用于 22A-2。22A-2 未实施时，不应把真实单题观察器 JSON 解析成功率作为 22A-1 的完成标准。

如果 22A-0 或 22A-1 指标不足，应停止在离线报告和旁路诊断，不继续建设机制卡和路由接入。如果 22A-2 指标不足，只停止真实观察器结果进入机制归纳，不影响 22A-1 旁路诊断继续产出。

17. 明确不做

首版不做以下事项：

- 不训练模型；
- 不把相对分数当奖励；
- 不把 `relative_advantage` 写入在线 `score_rate`；
- 不把 GPT 分数并入 Qwen 分数；
- 不把一次大模型解释写入正式记忆；
- 不让真实单题观察器全量运行；
- 不让机制归纳器自动发布机制卡；
- 不让机制卡自动创建新算子；
- 不用同一模型的高分回答替代人工或强外部正确性锚点；
- 不因旁路诊断修改候选选择、状态机或正式算子顺序；
- 不绕过 25 号全局记忆的发布、快照和回放验证流程。

18. 回滚

阶段 22A 的产物都是旁路数据。关闭开关、忽略 `behavior_analysis.jsonl` 或删除旁路产物，即可恢复当前主流程。

阶段 22B 的机制候选进入 25 号全局记忆发布流程后，回滚方式应沿用 25 号方案：

- 降级机制卡状态；
- 退役有问题的卡；
- 固定旧快照继续恢复旧实验；
- 新实验切回无全局记忆或只审计模式。

阶段 22C 如果进入有限路由实验，必须保留完整回退路径：关闭机制提示、恢复原路由、保留审计记录，并重新比较关闭前后的实验结果。