

流程机制治理实施计划

流程机制治理实施计划

Prompt：流程机制治理实施

代码块

```
1  你是 Question Evolution 项目的实现 agent。当前任务是实施《28_规则基准拆分0731-流程机制治理实施计划》。
2
3  实施前先阅读：
4
5  1. 归档目录下的《问题进化规则约束问题》
6  2. 归档目录下的《题面信息职责隔离与全算子语义泄漏治理优化方案》
7  3. 归档目录下的《问题进化规则约束完整修改实施方案》
8  4. 父目录下的《27_规则基准拆分0731-算子内容治理实施计划》
9  5. 父目录下的《28_规则基准拆分0731-流程机制治理实施计划》
10
11 本任务只允许修改流程机制。不要重写 010-033 的具体题型内容；如果发现算子内容问题，只记录为依赖问题或测试失败原因，不在本任务内大改算子语义。
12
13 目标：
14
15 1. 让路由器根据目标失败模式选择算子，并让算子把题目合理变难，使弱模型在新题上稳定降分。
16 2. 题面编写器不能看到正确答案、旧评分标准、事实角色和预期弱模型错误。
17 3. 题目变化后，旧参考答案、旧评分标准和旧分数不能继续用于新题评分。
18 4. 允许构造题内假设场景、人物、实体、动作、路径、局部参数和竞争解释；禁止伪造真实外部事实、真实规则、专业阈值和真实案件结论。
19 5. 所有审核校验环节默认只记录诊断、风险标签、证据片段和建议动作，不直接作为阻拦依据。
20 6. 只有真实回答、重新评分、弱模型稳定降分和目标错误命中后，才能写成功经验。
21
22 重点修改对象：
23
24 1. `semantic_budget.py`
25 2. `question_evolution.py`
26 3. `prompts/source_analysis_prompt.py`
27 4. `prompts/evolution_planner_prompt.py`
28 5. `operator_router.py`
29 6. `router_contract.py`
30 7. `prompts/router_prompt.py`
31 8. `validate_evolved_question.py`
32 9. `validate_difficulty_gain`
```

33 10. `candidate\_selection.py`
34 11. `rebuild\_reference\_answer.py`
35 12. `prompts/reference\_rebuild\_prompt.py`
36 13. `gen\_rubric.py`
37 14. `collect\_answers.py`
38 15. `scoring.py`
39 16. `analyze\_evolution\_effect.py`
40 17. `update\_sample\_state.py`
41 18. `run\_loop.sh`
42 19. `resume\_run\_loop.sh`
43 20. 相关 schema 和测试文件

44

45 实施步骤：

46

47 第一步，先做评分材料隔离。

48

- 49 - 修改 `collect\_answers.py`，弱模型请求体只包含最终题面。
- 50 - 停止注入旧参考答案、答案边界、旧评分标准意图、隐藏规划、预期弱模型错误。
- 51 - 题目变化后，把旧参考答案、旧评分标准、旧分数标记为过期材料。
- 52 - 新题的活动评分状态写为 `not\_evaluated`。

53

54 第二步，新增任务授权和来源拆分。

55

- 56 - 新增任务授权读取逻辑，至少支持 `allowed\_evolution\_modes`、
`controlled\_hypothetical\_case\_authorized`、`controlled\_synthesis\_authorized`、
`hypothetical\_adaptation\_authorized`、`authorization\_source`、
`authorization\_id`。
- 57 - 缺少授权配置、配置不可解析、授权来源不可审计时，不得合成真实外部事实、真实规则、专业阈值
或真实案件结论；但仍可生成明确标注为题内设定的假设观察事实。
- 58 - 新增 `prompts/source\_analysis\_prompt.py`。
- 59 - 修改 `semantic\_budget.py`，不再把完整父题当成单一观察事实。
- 60 - 输出来源事实账本，包含 `fact\_id`、`world\_id`、`global\_fact\_key`、`origin\_type`、
`source\_locator`。
- 61 - 真实规则必须进入规则账本，记录来源、版本、适用范围、当前有效状态。

62

63 第三步，新增模式决策器。

64

- 65 - 输入为来源分析、样本资格、任务授权和允许模式。
- 66 - 输出必须包含 `evolution\_mode`、`mode\_reason`、`authorization\_checked`、
`authorization\_id`。
- 67 - 抽象题或信息不足题应优先选择题内假设构题模式，不能因为来源事实少就直接
`pass\_through`。
- 68 - `source\_faithful` 只限制来源事实保持，不代表所有进化都必须依赖原题已有槽位。
- 69 - 路由器、经验库、算子资格、槽位完整性都不能绕过模式决策器。

70

71 第四步，改造模式感知路由器。

72

73 - 修改 `operator\_router.py`, 删除默认 010 fallback。
74 - 修改 `router\_contract.py` 和 `prompts/router\_prompt.py`。
75 - 路由器按顺序执行: 真实外部事实/规则授权检查、进化模式检查、算子槽位检查、相邻算子消歧、经验库排序。
76 - 014 从生成算子退役, 作为 `validation\_only` 信息闭包校验组件保留, 永远不进入生成候选。
77 - 017 恢复为普通生成算子, 与其他生成算子同等参与自然路由; 不能用硬编码
`enabled=false`、低优先级封印或默认黑名单让它永久不参与选择。
78 - 没有安全算子时返回 `no\_safe\_operator`, 上层先记录空选原因和缺失槽位; 只有无法通过题内假设构题、换算子或重试修复时, 才转为 `pass\_through\_candidate`; 不得默认 fallback 到 010。
79 - 更新 route cache 版本, 旧缓存不能复用。
80
81 第五步, 拆分隐藏规划和盲写题面。
82
83 - 新增 `prompts/evolution\_planner\_prompt.py`。
84 - 隐藏规划器输出事实账本、竞争解释、正确答案轮廓、结论契约、控制计划、预期弱模型错误。
85 - 公开事实编译器只把允许公开的事实和中性任务交给题面编写器。
86 - 题面编写器只输出 `evolved\_prompt`、`used\_fact\_ids`、`surface\_notes`。
87 - 隐藏规划写入受限旁路产物, 不放进普通下游上下文。
88 - 任何阶段不得把完整 sample dict 直接传给题面编写器。
89
90 第六步, 接入新校验器, 先影子运行。
91
92 - 修改 `validate\_evolved\_question.py`, 按 L0-L6 顺序校验。
93 - L0 检查身份、Schema、旧评分状态。
94 - L1 检查事实来源、规则有效性、世界一致性、模式合规。
95 - L2 检查可答性、事实冲突、题外知识。
96 - L3 检查答案泄漏和单句直达答案。
97 - L4 检查复杂度、竞争存活、信息量平衡。
98 - L5 检查消融、名称交换、顺序交换。
99 - L6 检查预测结构收益。
100 - 校验器始终只记录诊断、风险标签、证据片段和建议动作; 不直接删除候选, 不直接阻断参考答案重建、弱模型回答或评分。
101
102 第七步, 启用定向重试和候选分流。
103
104 - 修改 `candidate\_selection.py`, 优先读取 `validation\_disposition.status`。
105 - 区分 `record\_only\_risk`、`retry\_same\_operator`、`exploration\_candidate`、
`needs\_manual\_review`、`pass\_through\_candidate`。
106 - 同一标签最多重试一次, 同一候选最多重试两次。
107 - 无来源事实、世界混合、编造真实规则、不可答、事实矛盾记录为高风险诊断; 候选选择阶段优先定向重试或人工复核。只要候选技术可执行且参考答案、Rubric 可以重建, 就继续弱模型真实回答和评分。
108 - 竞争偏弱、难度收益不确定、轻微信息量偏差进入预算内探索。
109 - 新契约产生的 `needs\_manual\_review` 默认记录并进入人工复核队列, 同时继续参考答案重建、弱模型回答和正式评分。只有确定性技术不可执行、参考答案或 Rubric 完全无法生成、版本不一

致、模型/评分器无法恢复，或 `execution\_scope` 明确不允许下游阶段时，才跳过弱模型回答或正式评分。

第八步，重建参考答案和评分标准。

- 新增 `rebuild\_reference\_answer.py` 和 `prompts/reference\_rebuild\_prompt.py`。
- 只对选中候选重建参考答案，未选候选不生成正式新答案。
- 新参考答案必须引用公开事实和有效规则。
- 新参考答案通过独立核验后，才允许进入 `gen\_rubric.py`。
- `gen\_rubric.py` 只读取已核验的新参考答案。
- 调整默认顺序为：`candidate\_selection` -> `rebuild\_reference\_answer` -> `gen\_rubric` -> `collect\_answers` -> `scoring`。
- `scoring.py` 发现题目版本、参考答案版本或评分标准版本不一致时必须停止。

第九步，改造效果确认、经验库和下一轮决策。

- 修改 `analyze\_evolution\_effect.py`，判断稳定降分、目标错误命中、强答案正确、评分器稳定、替代原因排除。
- 修改 `update\_sample\_state.py`，只有确认或准确效果才写成功经验。
- `score\_increased` 继续写失败经验，不能写成功经验。
- 每个完成效果分析的候选必须输出 `next\_round\_decision`。
- `next\_round\_decision` 至少支持：`continue\_same\_operator`、`switch\_operator`、`retry\_generation\_strategy`、`backtrack\_to\_parent`、`retain\_as\_boundary`、`stop\_branch\_success`、`stop\_branch\_no\_gain`、`pass\_through`、`manual\_review`。

第十步，加入执行范围门禁。

- 新增 `execution\_scope`。
- 开发调试范围未授权时，不得发起弱模型回答和评分器评分。
- 正式入口缺少模型、评分器、参考答案重建、评分标准重建或完整运行范围时，启动前报错。
- 只有真实回答、评分和效果归因完成后，才允许产生效果声明。

禁止事项：

1. 不要把任务授权和样本资格混为一谈。
2. 不要让经验库授予真实外部事实或真实规则合成权限、补齐真实事实或覆盖门禁。
3. 不要让题面编写器看到旧答案、旧评分标准、隐藏规划或目标错误。
4. 不要用旧分数说明新题效果。
5. 不要在参考答案未核验前生成新评分标准。
6. 不要把所有不确定项都转人工；低风险结构不确定项应进入预算内探索。
7. 不要在结构校验通过后宣称有效进化。
8. 不要把校验结果直接作为阻拦依据；校验只记录，候选选择负责根据实验目标执行建议动作。

验收标准：

1. 真实外部事实、真实规则、专业阈值和真实案件结论不会被伪造成题内事实；题内假设构题默认允许并受账本约束。

150 2. 014 不会进入路由器生成候选，只作为信息闭包校验组件运行。
151 3. 017 作为普通生成算子参与默认自然路由。
152 3. 题面编写器上下文中隐藏字段数量为 0。
153 4. 答案泄漏、不可答题和事实矛盾会被记录、重试或复核；无法修复且会破坏实验有效性的候选不会
进入正式评分。
154 5. 新题评分前都有已核验的新参考答案和新评分标准。
155 6. 弱模型只看最终题面。
156 7. `score\_increased` 不写成功经验。
157 8. 每个完成效果分析的候选都有可执行的 `next\_round\_decision`。
158 9. 正式 `full\_iteration` 能完整跑到效果归因和下一轮决策。
159
160 完成后输出实施报告：
161
162 1. 每个阶段完成了哪些改动。
163 2. 新增或修改了哪些 schema。
164 3. 新增或修改了哪些测试。
165 4. 哪些测试已运行，结果如何。
166 5. 哪些功能仍处于影子运行，哪些已经正式生效。
167 6. 是否存在需要算子内容治理任务配合修复的问题。

1. 文档定位

本文只规定系统如何选择进化模式、如何路由、如何隔离生成上下文、如何校验、如何重试和分流、如何重建参考答案与评分标准、如何评分、如何写经验库和进入下一轮。

本文不重复 O10-O33 的具体题型要求。每个算子的题面规则、禁止泄漏项和控制测试由《0731规则基准拆分：算子内容治理实施计划》负责。

2. 基准与边界

本方案以归档的三份基准文档为依据：

文档位置：docs/后续优化方案/问题进化规则约束修改及算子语义泄露治理-0731/

- 《问题进化规则约束问题》：提供任务授权、事实来源、受控合成和有效进化判定规则。
- 《题面信息职责隔离与全算子语义泄露治理优化方案》：提供隐藏规划器、题面编写器、校验器的职责隔离要求。
- 《问题进化规则约束完整修改实施方案》：提供工程模块、阶段顺序和验收要求。

与《27_规则基准拆分0731：算子内容治理实施计划》的边界如下：

3. 总体目标

机制优化的最高目标是让进化真正有效：系统根据路由选择合适算子，把原题改造成更难但仍合理、可回答、可评分的新题；弱模型在新题上稳定降分时，才认为找到了对应能力边界。

本方案中的来源拆分、题面隔离、校验、参考答案重建和评分版本控制都服务于这个目标。它们不是为了阻碍进化，也不是为了添加越多越好的审核规则。

机制优化要解决五个问题：

- 1. 信息不足时，系统可以构造题内假设场景、人物、实体、动作、路径、局部参数和竞争解释，用于形成有效难题。
- 2. 题面编写器不能看到正确答案、旧评分标准、事实角色和预期弱模型错误。
- 3. 题目变化后，旧参考答案、旧评分标准和旧分数不能继续用于新题。
- 4. 校验和审核只记录诊断、风险标签、重试建议和人工 review 线索，默认不直接阻断主链。
- 5. 只有真实回答和重新评分证明弱模型稳定降分且命中目标错误后，才能写成功经验。

4. 总体流程

正式流程调整为：

代码块

- 1 读取任务授权和执行范围
- 2 -> 识别来源事实场景
- 3 -> 拆分原始输入
- 4 -> 选择进化模式
- 5 -> 选择算子
- 6 -> 隐藏规划
- 7 -> 编译公开事实
- 8 -> 盲写题面
- 9 -> 独立校验并记录诊断
- 10 -> 根据诊断给出重试、探索、复核或透传建议
- 11 -> 重建新参考答案并核验
- 12 -> 重建新评分标准
- 13 -> 弱模型只看题面回答
- 14 -> 使用新评分标准评分

```
15  -> 效果归因
16  -> 写经验库
17  -> 输出下一轮决策
```

开发、调试和回放可以停在结构检查；正式实验必须跑完整闭环。缺少必要配置时，正式入口应直接报错，不能静默降级为“只做结构检查也算成功”。

校验结果不是天然阻拦条件。正式实验应优先让可修复、可探索、可评分的候选进入后续回答和评分，用真实弱模型得分判断是否有效；校验只负责记录风险和给出处理建议。

5. 阶段一：评分材料隔离

5.1 修改目标

先阻断最直接的答案污染。弱模型回答新题时，只能看到最终题面。

5.2 修改内容

- 修改 `collect_answers.py`，停止注入旧参考答案、答案边界、评分标准意图、隐藏规划和预期失败。
- 题目变化后，将旧 `rubric`、`score_prompt`、`scoring_result`、`score_rate` 标记为过期材料。
- 新题的活动评分状态写为 `not_evaluated`。
- `validate_difficulty_gain.py` 在真实评分前只能判断结构潜力，不能宣称有效进化。

5.3 验收标准

- 弱模型请求体只包含最终题面。
- 新题没有新参考答案和新评分标准时，不能进入正式评分。
- 旧分数不能被用来说明新题变难或变易。

6. 阶段二：任务授权与来源拆分

6.1 修改目标

先判断本次任务允许做什么，再判断样本适合做什么。这里的“授权”只限制真实外部事实、真实规则、专业阈值和真实案件结论的伪造，不应禁止题内假设构题。

6.2 新增数据

新增任务授权信息：

代码块


```
1 {"evolution_authorization": {"allowed_evolution_modes": ["source_faithful",  
  "controlled_hypothetical_case", "controlled_synthesis",  
  "hypothetical_adaptation_from_source"],"controlled_hypothetical_case_authorized": true,  
  "controlled_synthesis_authorized": true,  
  "hypothetical_adaptation_authorized": true,"authorization_source": "task_config",  
  "authorization_id": "task_policy_001"}}
```

缺少配置、配置不可解析、授权来源不可审计时，不得合成真实外部事实、真实规则、专业阈值或真实案件结论；但仍可生成明确标注为题内设定的假设观察事实。此类假设事实必须登记到事实账本，并能说明服务于哪个算子槽位或竞争结构。

6.3 修改内容

- 新增 `prompts/source_analysis_prompt.py`，把原题拆成观察事实、来源主张、原始规则、答案方向、推导总结。
- 修改 `semantic_budget.py`，删除“完整父题就是单一观察事实”的默认行为。
- 新增来源事实账本，写入 `fact_id`、`world_id`、`global_fact_key`、`origin_type`、`source_locator`。
- 真实规则进入规则账本，必须记录来源、版本、适用范围和当前有效状态。
- 来源分析器只判断样本资格，不授予模式权限。

6.4 验收标准

- 父题中的“不能直接认定”“最高支持”等答案方向不会进入题面编写器输入。
- 每个公开事实都能找到来源或受控假设登记。
- 真实外部事实、真实规则和专业阈值不会被伪造成题内已知事实。
- 题内假设人物、实体、动作、路径、局部参数和竞争解释可以生成，但必须登记、同世界、自治、可回答。

7. 阶段三：进化模式选择

7.1 四种模式

- `source_faithful`：只重组已有事实，不新增来源事实。
- `controlled_hypothetical_case`：默认允许建立独立题内假设案例，并新增人物、实体、动作、路径、局部参数、竞争解释等观察事实。
- `controlled_synthesis`：任务授权后，允许把题内假设案例扩展到更完整的训练场景，但仍不能伪造真实规则、真实法规或真实专业阈值。
- `hypothetical_adaptation_from_source`：任务授权后，允许把来源原则改编成新的假设案例。

7.4.2 七类进化方向承接

7.4.3 具体进化方法承接

7.4.4 题内假设合成承接

表内方向以及其他新增合理方向进入流程后，都必须满足统一记录要求：

- 新增或重组的信息必须写入来源事实账本、受控假设账本或规则账本，并保留 `fact_id`、`world_id`、`global_fact_key`、`origin_type` 和 `source_locator` 或假设登记依据。
- 路由器不得因为题面包含题内规则、局部参数、竞争解释、干扰事实或中性改写就判定为违规；只能按模式、授权、槽位来源和不可合成材料判断是否适配当前算子。
- 校验器发现泄漏、不可答、事实矛盾、竞争偏弱、信息量失衡或合成风险时，默认记录诊断、证据和建议动作；只要技术可执行且参考答案、Rubric 可以重建，仍继续真实回答和评分。
- 经验库可以记录哪些进化方向更容易暴露能力边界或更容易失败，但不能授予真实外部事实合成权限、补齐缺失事实或覆盖模式决策器。

8. 阶段四：模式感知路由器

8.1 修改目标

让规则路由器和混合路由器使用同一套准入语义。关键词只能召回候选，不能直接给执行资格。

8.2 路由层级

路由器按以下顺序执行：

代码块

- ```
1 任务授权检查
2 -> 进化模式检查
3 -> 算子槽位检查
4 -> 相邻算子消歧
5 -> 经验库排序
```

经验库只能参与最后排序，不能补齐真实外部事实、授予真实规则合成权限或覆盖前面门禁。经验库可以建议哪类题内假设结构更容易暴露弱模型能力边界。

### 8.3 路由治理规则

路由器必须把“找不到合适算子”作为可观测实验状态，而不是静默兜底到某个默认算子。

## 1. 取消默认 O10 fallback。

- O10 只在其槽位、模式和样本资格真正满足时参与竞争。
- 如果所有生成算子都不适用，路由器返回 `no_safe_operator`，不得自动改写为 O10。
- `no_safe_operator` 必须记录分析原因，包括候选算子清单、每个算子的缺失槽位、模式不匹配、授权限制、事实来源限制和经验库排序前后的状态。
- 该记录用于后验分析“样本为什么没有进入进化生成”，不能被写成有效进化失败，也不能让整轮实验停止。

## 2. O14 从生成算子退役，转为信息闭包校验。

- O14 的定位是信息闭包、事实来源、世界一致性和非法规则风险的校验原则，不是生成题面的算子。
- O14 不进入自然路由、候选生成、fallback 或算子探索队列。
- O14 不一定马上从代码库彻底删除；可以保留为校验组件、兼容旧产物的解析入口或历史回放标识。
- O14 输出只进入诊断、风险记录、重试建议和后验分析，不直接决定 `skip_answer`、`skip_scoring` 或 `stop_pipeline`。

## 3. O17 恢复为普通生成算子。

- O17 已有明确题型能力和内容契约，不能因为历史上被主动关闭就排除在默认生成之外。
- 除 O14 这类明确 `validation_only` 的算子外，所有给定生成算子地位相同，都应进入同一套路由准入检查。
- O17 只能因与其他算子相同的规则被排除：样本不满足槽位、模式不合规、授权不足、事实来源不足或当前单次调试范围显式排除；这种排除必须记录原因，不能成为默认配置。
- 不允许使用硬编码 `enabled=false`、低优先级封印或默认路由黑名单让 O17 永久不参与自然路由；如果 O17 缺少当前样本所需材料，应记录为槽位缺失，而不是算子级关闭。

## 8.4 修改内容

- 修改 `operator_router.py`，删除默认 O10 fallback。
- 修改 `router_contract.py` 和 `prompts/router_prompt.py`，新增来源分析、任务授权、进化模式、槽位状态和 `no_safe_operator` 原因记录。
- 在算子注册或路由配置中区分 `generation` 与 `validation_only`；O14 永远不进入生成候选，但可以接入校验链。
- 移除 O17 的默认关闭状态，让 O17 与其他生成算子同等参与自然路由。
- 没有安全算子时返回 `no_safe_operator`，上层记录空选原因、缺失槽位和可改进方向；不能静默兜底到 O10，也不能把路由空选写成内容审核失败。
- 更新 route cache 版本，旧缓存不能复用。

## 8.5 验收标准

- `source_faithful` 下，所有必需槽位必须来自来源事实。
- 题内假设构题模式下，可以合成人物、实体、动作、路径、局部参数、竞争解释和相关干扰事实。
- 任何模式下都不能合成真实规则、真实法规、真实专业阈值或冒充现实已发生的案件事实。
- 单个算子不适用时继续检查其他生成算子；全部不适用时记录原因并输出 `no_safe_operator`，不得默认回退到 O10。
- O14 只作为信息闭包校验运行，不出现在生成候选、fallback 候选或自然路由结果中。
- O17 出现在默认生成算子池中，且只按统一槽位、模式、授权和来源规则被接受或拒绝。

## 9. 阶段五：隐藏规划与盲写题面

### 9.1 修改目标

同一次模型调用不能既掌握答案结构又写最终题面。

### 9.2 修改内容

- 新增 `prompts/evolution_planner_prompt.py`。
- 隐藏规划器输出事实账本、竞争解释、正确答案轮廓、结论契约、控制计划、预期弱模型错误。
- 公开事实编译器只把允许公开的事实和中性任务交给题面编写器。
- 题面编写器只输出 `evolved_prompt`、`used_fact_ids`、`surface_notes`。
- 隐藏规划写入受限旁路产物，不放进普通下游上下文。

### 9.3 验收标准

- 题面编写器请求快照不包含旧答案、评分标准、`answer_role`、`target_error`、评分器意图。
- 题面编写器生成的每个事实都能在公开事实投影中找到。
- 题面不能出现未登记事实、答案方向或内部事实角色。

## 10. 阶段六：新校验器

### 10.1 修改目标

校验器不再只看词面禁词，而是检查事实来源、可答性、答案泄漏、竞争结构和控制测试。校验器的默认职责是记录诊断，不直接阻断主链。

### 10.2 校验顺序

- 1 L0: 身份、Schema、旧评分状态
- 2 L1: 事实来源、规则有效性、世界一致性、模式合规
- 3 L2: 可答性、事实冲突、题外知识
- 4 L3: 答案泄漏、单句直达答案
- 5 L4: 复杂度、竞争存活、信息量平衡
- 6 L5: 消融、名称交换、顺序交换
- 7 L6: 预测结构收益

校验结果逐层记录。更贵的检查可以按预算运行，但前一层出现风险不必立刻中断；即使题面存在疑似不可答、泄漏答案、事实矛盾、严重改题或合成风险，也应继续产出完整诊断，便于后续重试和分析。只有 JSON 无法解析、必填字段缺失、题目为空、输出不是可发送给弱模型的问题等确定性技术不可执行问题，才允许停止本候选的下游执行。

## 10.3 处置规则

- 无来源事实、世界混合、编造真实规则、不可答、事实矛盾：记录为高风险诊断，候选选择阶段优先定向重试或转人工复核；如果候选技术上仍可发送、可重建评分材料，则继续进入真实回答和评分，并在后验分析中标记风险影响。
- 规则应用泄漏、角色绑定泄漏、链条总结、答案方向泄漏：记录泄漏标签和证据片段，定向重试一次；重试后仍有泄漏风险的候选继续作为高风险样本运行，不能仅凭泄漏诊断退出主链。
- 竞争偏弱、难度收益不确定、轻微信息量偏差：记录为探索风险，默认进入预算内探索。
- 来源、规则版本、答案唯一性、隐藏事实使用无法确认：记录为人工 review 线索；不直接作为全局阻拦。
- 不适用的检查写 `not_applicable`，不能当作失败。

## 10.4 验收标准

- 新校验器始终输出结构化诊断、风险标签、证据片段和建议动作。
- 即使切到正式生效，校验器也不直接删除候选；正式主链由 `candidate_selection.py` 根据诊断、预算和实验目标决定重试、探索、复核或透传。
- `candidate_selection.py` 优先读取 `validation_disposition.status`，但不能只看顶层 `passed=false`，也不能把所有 unresolved 自动阻断。

# 11. 阶段七：定向重试与候选分流

## 11.1 修改目标

可修的问题优先修；结构不确定、有泄漏风险或存在内容风险但技术可执行、可评分的候选仍保留探索机会。候选分流以“尽量完成有效变难实验”为目标，不以阻断为目标。

## 11.2 重试预算

代码块

```
1 {"retry_budget": {"max_retries_per_label":
 1, "max_total_retries_per_candidate": 2}}
```

同一标签最多重试一次；同一候选最多重试两次。

## 11.3 修改内容

- 修改 `candidate_selection.py`，区分 `record_only_risk`、`retry_same_operator`、`exploration_candidate`、`needs_manual_review`、`pass_through_candidate`。
- 旧数据中没有高风险证据的 `needs_manual_review` 可以兼容映射为探索候选。
- 新契约产生的 `needs_manual_review` 默认记录并进入人工复核队列，同时继续参考答案重建、弱模型回答和正式评分。
- 只有确定性技术不可执行、参考答案或评分标准完全无法生成、版本不一致、模型/评分器调用无法恢复，或 `execution_scope` 明确不允许下游阶段时，才跳过弱模型回答或正式评分。

## 11.4 验收标准

- 泄漏风险会被记录并触发定向重试；重试后仍泄漏答案的候选作为高风险样本继续进入真实回答和评分，后验分析时不得直接确认为有效边界。
- 弱竞争不会被全量阻断，应进入预算内探索或记录为低效变难原因。
- 无安全进化方式时，输出 `no_safe_operator` 或透传当前样本并记录原因，不把整轮实验停住。

## 12. 阶段八：参考答案与评分标准重建

### 12.1 修改目标

题目变了，就必须重建参考答案和评分标准。旧材料只能审计，不能继续作为活动评分材料。

### 12.2 默认顺序

代码块

```
1 candidate_selection
2 -> rebuild_reference_answer
3 -> gen_rubric
4 -> collect_answers
5 -> scoring
```



## 12.3 修改内容

- 新增 `rebuild_reference_answer.py` 和 `prompts/reference_rebuild_prompt.py`。
- 参考答案重建器只对选中候选运行，未选候选不生成正式新答案。
- 新参考答案必须引用公开事实和有效规则。
- 参考答案核验器检查新答案是否偷用仅隐藏事实，是否存在多个合理冲突答案。
- `gen_rubric.py` 只读取已核验的新参考答案。
- `collect_answers.py` 保持只给弱模型最终题面。

## 12.4 验收标准

- 新参考答案未通过独立核验时，不能进入评分标准重建。
- 评分标准未重建时，不能收集弱模型正式回答。
- 评分阶段发现题目版本、参考答案版本或评分标准版本不一致时必须停止。

# 13. 阶段九：效果确认、经验库和下一轮

## 13.1 有效进化条件

只有同时满足以下条件，才能写成功经验：

1. 弱模型多次回答后稳定降分。
2. 错误命中当前算子的目标能力。
3. 新参考答案或强模型答案正确。
4. 评分器评分稳定。
5. 题面没有会破坏实验有效性的答案泄漏、不可答或事实冲突问题；普通审核风险已经记录并可追溯。
6. 降分不是由格式复杂、任务堆叠或评分标准污染造成。

## 13.2 修改内容

- 修改 `analyze_evolution_effect.py`，新增效果确认字段。
- 修改 `update_sample_state.py`，只有确认或准确认效果才写 success memory。
- `score_increased` 继续写失败经验，不能写成功经验。
- 经验库只记录具体失败形态或成功证据，不能授予模式权限或补齐事实。
- 每个完成效果分析的候选输出 `next_round_decision`。

- 当前暂不开启纵向算子叠加。稳定降分且目标错误命中的候选只保留为边界样本并停止当前分支，不自动继续同算子加一级难度。

### 13.3 next\_round\_decision

当前启用动作：

代码块

```
1 switch_operator
2 retry_generation_strategy
3 backtrack_to_parent
4 retain_as_boundary
5 stop_branch_success
6 stop_branch_no_gain
7 pass_through
8 manual_review
```

`continue_same_operator` 涉及纵向算子叠加，当前不作为自动 `next_round_decision` 输出。后续若要启用，必须由单独方案定义显式开关、难度预算、终止条件和回归测试。

例子：

- 稳定降分且目标错误命中：保留为边界样本，输出 `retain_as_boundary` 和 `stop_branch_success`，当前分支立即停止。
- 分数下降但目标错误不明确：换生成策略，不写成功经验。
- `score_increased`：写失败经验，返回直接父题并换算子。
- 无安全进化方式：透传当前样本，继续处理其他样本。

## 14. 执行范围门禁

### 14.1 运行范围

新增 `execution_scope`，控制本次运行最多执行到哪个阶段。

开发调试可以使用：

代码块

```
1 {"execution_scope": {"max_stage":
 "structure_validation", "allow_model_answering": false, "allow_judge_scoring":
 false, "allow_effect_claim": false}}
```

正式实验必须使用完整运行范围：

代码块

```
"execution_scope": {"max_stage": "full_iteration", "allow_reference_rebuild": true, "allow_model_answering": true, "allow_judge_scoring": true, "allow_effect_claim": true}}
```

14.2 验收标准

- 开发范围未授权时，不会发起弱模型回答和评分器评分。
- 正式入口缺少模型、评分器、参考答案重建、评分标准重建或完整运行范围时，启动前报错。
- 只有真实回答、评分和效果归因完成后，才允许产生效果声明。

15. 文件级实施清单

|  |  |
|--|--|
|  |  |
|  |  |
|  |  |
|  |  |
|  |  |
|  |  |
|  |  |
|  |  |
|  |  |
|  |  |
|  |  |
|  |  |
|  |  |
|  |  |
|  |  |
|  |  |
|  |  |
|  |  |
|  |  |

16. 测试计划

16.1 必测样本

- 未授权合成样本。
- 已授权受控合成样本。
- 真实案件事实不可修改样本。
- 无来源事实样本。

- 世界混合样本。
- 真实规则缺来源或过期样本。
- 答案方向泄漏样本。
- 角色绑定泄漏样本。
- 链条总结泄漏样本。
- 旧参考答案污染样本。
- `score_increased` 样本。

## 16.2 必测流程

- 来源分析器不把参考答案当事实来源。
- 模式决策器不把样本资格当任务授权。
- 路由器找不到合适算子时不回退到 O10，而是记录 `no_safe_operator`、缺失槽位和分析原因。
- 路由器不让 O14 进入生成候选，但 O14 可以作为信息闭包校验组件运行。
- O17 默认进入生成算子池，并按统一准入规则参与自然路由。
- 题面编写器请求中没有隐藏字段。
- 校验器在影子运行时不改变正式分流。
- 正式生效后，泄漏、不可答、事实矛盾、严重改题等内容风险先被记录、重试或复核；只要技术可执行且评分材料可生成，就继续真实回答和评分。
- 新参考答案核验失败时停止在评分标准重建前。
- 弱模型请求体只有最终题面。
- `score_increased` 只写 failure memory。
- `next_round_decision` 可以被下一轮直接消费。

## 17. 发布顺序

1. 先合入评分材料隔离，阻断旧答案污染。
2. 合入来源拆分、任务授权和模式决策器，先影子记录。
3. 合入模式感知路由器，取消默认 O10 fallback，设置 O14 为 `validation_only`，恢复 O17 自然路由，并保持旧结果对照报告。
4. 合入隐藏规划器与盲写题面，上下文隔离测试必须通过。
5. 合入新校验器，先影子运行并产出诊断报告。
6. 校准后开启定向重试和候选分流；校验器仍只记录结果，候选选择负责执行建议动作。

7. 合入参考答案与评分标准重建，调整 run loop 顺序。
8. 合入效果确认、经验库和下一轮决策。
9. 对除 O14 这类 `validation_only` 组件外的所有生成算子开放自然路由；强制资格测试只作为诊断和回归修复依据，不作为默认关闭某个生成算子的发布门槛。

## 18. 完成标准

满足以下条件后，机制优化可以进入正式实验：

- 真实外部事实、真实规则、专业阈值和真实案件结论不会被伪造成题内事实；题内假设构题默认允许并受账本约束。
- O14 不会进入路由器生成候选。
- O17 作为普通生成算子参与默认路由，不再被静态关闭。
- 除 O14 这类 `validation_only` 组件外，所有给定生成算子都按同一套路由准入规则参与选择。
- 找不到合适算子时记录 `no_safe_operator`、缺失槽位和分析原因，不默认 fallback 到 O10。
- 题面编写器上下文中隐藏字段数量为 0。
- 答案泄漏、不可答题、事实矛盾和严重改题会被记录、重试或复核；只要技术可执行且评分材料可生成，就继续进入弱模型回答和正式评分。
- 新题评分前都有已核验的新参考答案和新评分标准。
- 弱模型只看最终题面。
- `score_increased` 不写 success memory。
- 每个完成效果分析的候选都有可执行的 `next_round_decision`。
- 正式 `full_iteration` 能完整跑到效果归因和下一轮决策。

