

算子内容治理实施计划

算子内容治理实施计划

Prompt：算子内容治理实施

代码块

```
1  你是 Question Evolution 项目的实现 agent。当前任务是实施《27_规则基准拆分0731-算子内容治理实施计划》。
2
3  实施前先阅读：
4
5  0. 项目根目录下的《全局规则约束》
6
7  1. 归档目录下的《问题进化规则约束问题》
8  2. 归档目录下的《题面信息职责隔离与全算子语义泄漏治理优化方案》
9  3. 归档目录下的《问题进化规则约束完整修改实施方案》
10 4. 父目录下的《27_规则基准拆分0731-算子内容治理实施计划》
11 5. 父目录下的《28_规则基准拆分0731-流程机制治理实施计划》
12
13 本任务只允许修改算子内容治理相关内容。不要实现路由、评分、参考答案重建、评分标准重建、候选分流、经验库写入和运行顺序改造；这些属于流程机制治理任务。
14
15 目标：
16
17 1. 让 010-033 每个算子都有清晰的题面生成规则。
18 2. 删除题面中的答案方向、推理链总结、事实角色提示、规则应用结果和竞争解释淘汰提示。
19 3. 保证 014 只作为信息闭包校验原则，不生成独立题面。
20 4. 为每个生成算子补齐执行契约和内容测试。
21 5. 保证内容测试和离线压测只产出风险统计、灰度建议和优化依据，不作为在线硬阻断。
22
23 重点修改对象：
24
25 1. `prompts/operators/base.py`
26 2. `prompts/operators/010...033`
27 3. `operator_execution_contracts.py`
28 4. 与算子内容契约相关的测试文件
29
30 实施步骤：
31
32 第一步，建立算子内容基线。
33
```

34 - 扫描 010-033 的 `OperatorPromptSpec`。

35 - 列出每个算子当前是否存在以下问题：答案方向问法、完整链条总结、角色预绑定、规则应用结果、竞争解释淘汰、格式复杂度制造难度。

36 - 不要只检查 027、028、031；010-033 都必须进入清单。

37

38 第二步，新增 `operator\_execution\_contracts.py`。

39

40 - 为每个算子提供执行契约。

41 - 每个契约至少包含：`operator\_id`、`supported\_modes`、`primary\_axis`、
`allowed\_auxiliary\_axes`、`required\_slots`、`synthesizable\_slots`、
`non\_synthesizable\_slots`、`neutral\_task\_intent`、`required\_checks`、
`requires\_live\_competitor`。

42 - `required\_slots` 不得默认全部写入 `non\_synthesizable\_slots`；题内人物、实体、动作、路径、局部参数、观察记录和竞争解释可以在授权模式下作为可合成槽位。

43 - `non\_synthesizable\_slots` 只写真实法规、真实专业阈值、真实机构规则、真实外部记录、真实案件事实和业务结论等不可编造内容。

44 - 该文件只描述算子需要什么材料，不写自然题面。

45 - 014 的契约必须明确：不生成题面，只参与信息闭包校验。

46

47 第三步，收紧 `prompts/operators/base.py` 的输出要求。

48

49 - 题面编写器最终只允许输出 `evolved\_prompt`、`used\_fact\_ids`、`surface\_notes`。

50 - 删除或隔离 `expected\_qwen\_failure`、`expected\_evaluation\_focus`、
`target\_subclaim`、`boundary\_hypothesis`、答案提示类字段。

51 - 保留必要的历史兼容读取，但新生成结果不能继续写入答案侧字段。

52

53 第四步，按组修订算子文件。

54

55 - 先修 010-018，确认 014 不生成题面。

56 - 再修 019-027。

57 - 最后修 028-033。

58 - 每个算子的 `goal` 只描述隐藏能力目标。

59 - 每个算子的 `required\_question\_shape` 必须是中性问法，只保留一个用户可见业务任务；内部可以包含多个服务同一任务的事实关系和辅助推理点。

60 - 每个算子的 `forbidden\_shortcuts` 必须列出该算子最常见泄漏形式。

61 - 每个算子的 `content\_controls` 必须包含决定性事实消融、无关事实消融、名称交换或顺序交换中适用的检查。

62

63 第五步，为每个算子补测试。

64

65 至少覆盖：

66

67 - 正例：算子适用且题面无泄漏。

68 - 负例：算子不适用或槽位不足。

69 - 泄漏反例：题面直接写出答案方向、角色绑定、规则应用或完整链条。

70 - 决定性事实消融：删除决定性事实后结论减弱、无法区分或改变。

71 - 无关事实消融：删除干扰事实后答案保持不变。

- 72 - 名称交换或顺序交换：答案不应因名称、位置、顺序变化。
- 73
- 74 第六步，运行相关测试和离线压测。
- 75
- 76 - 每个生成算子建议离线抽样不少于 20 个候选，用于观察答案泄漏、格式伪难、槽位缺失、非法合成和相邻算子漂移。
- 77 - 20 个候选不是理论阈值；压测结果写入风险统计、灰度建议和后续优化，不得直接变成在线硬阻断。
- 78
- 79 第七步，运行相关测试。
- 80
- 81 - 优先运行算子 prompt、算子内容、算子路由卡生成相关测试。
- 82 - 如果新增测试文件，文件名要清楚表达测试目标。
- 83 - 如果现有测试因旧字段依赖失败，只允许增加兼容层或更新测试期望，不要恢复答案侧字段进入题面编写器。
- 84
- 85 禁止事项：
- 86
- 87 1. 不要改 `collect\_answers.py`、`gen\_rubric.py`、`scoring.py` 的运行顺序。
- 88 2. 不要把参考答案重建、评分标准重建或效果确认塞进算子任务。
- 89 3. 不要让 014 回到生成候选。
- 90 4. 不要用“缩短题目”代替语义泄漏治理。
- 91 5. 不要把真实法规、真实专业阈值、真实机构规则、真实外部记录、真实案件事实或业务结论写成可合成事实。
- 92 6. 不要把内容风险、人工 review 或离线压测结果直接包装成自然路由硬阻断。
- 93
- 94 验收标准：
- 95
- 96 1. 010-033 全部完成内容审查和必要修改。
- 97 2. 014 保持不生成独立题面。
- 98 3. 每个生成算子都有执行契约。
- 99 4. 每个生成算子都有正例、负例、泄漏反例和控制测试。
- 100 5. 题面编写器输出不包含答案、评分标准、目标错误、事实角色或评分器意图。
- 101 6. 离线压测结果只作为风险统计和灰度建议，不默认阻断主链。
- 102 7. 人工抽查题面时，看不到“最高支持”“不能直接认定”“缺少第几跳”“关键证据”等答案提示。
- 103
- 104 完成后输出实施报告：
- 105
- 106 1. 修改了哪些算子。
- 107 2. 每个算子修复了哪类泄漏。
- 108 3. 新增或修改了哪些测试。
- 109 4. 哪些测试已运行，结果如何。
- 110 5. 哪些算子建议灰度、继续 forced qualification 或优先人工复核，并说明依据。

1. 文档定位

本文只负责 O10-O33 的题面内容治理：每个算子应生成什么题面、哪些话不能写进题面、需要哪些槽位和内容测试。

本文不负责路由、候选分流、参考答案重建、Rubric 重建、弱模型回答、评分、经验库写入和运行顺序。这些属于流程机制治理任务。

本文必须服从 **全局规则约束**：内容检查只能记录风险和改进建议，不能把“疑似泄漏、疑似伪难、疑似竞争不足、疑似信息不闭合”默认变成在线硬阻断。

2. 读者和目标

读者是后续实现 agent 和人工 reviewer。读完后应能完成四件事：

1. 修改 O10-O33 的 `OperatorPromptSpec`，让题面问法保持中性。
2. 编写 `operator_execution_contracts.py`，说明每个算子需要哪些材料。
3. 补齐每个生成算子的正例、负例、泄漏反例和控制测试。
4. 人工抽查题面时，能判断题面是否把答案方向或推理链提前写出。

3. 与流程机制的边界

事项 | 本方案负责 | 流程机制负责

算子题面规则 | 写清每个算子允许和禁止的题面内容 | 读取规则并组织生成流程

算子槽位 | 说明每个算子需要哪些材料、哪些可题内合成、哪些不可合成 | 判断当前样本和模式是否满足槽位

内容测试 | 定义正例、负例、泄漏反例、消融和交换检查 | 执行测试、统计结果、决定重试或探索

O14 | 定义为信息闭包校验原则，不生成题面 | 从生成候选中排除，并接入校验链

质量压测 | 定义离线压测口径 | 选择是否灰度、重试、人工复核或继续真实运行

4. 内容治理总规则

4.1 题面只能写什么

- 可观察事实：时间、地点、动作、对象、记录、数值、画面条件。
- 题内明确给出的规则、公式、单位、局部参数。
- 竞争解释所需的对称事实。
- 一个用户可见的业务判断任务。

“一个用户可见任务”不是“只能有一个推理点”。例如，路径题可以同时包含时间窗、端点、路径约束和竞争车辆，但题面只问：“能否认定两段记录属于同一车辆，并说明依据。”

4.2 题面不能写什么

- 答案方向：如“不能直接认定”“最高只能支持”“为什么不成立”。
- 事实角色：如“关键证据是”“决定性事实是”“干扰事实是”。
- 推理链总结：如“第一跳成立、第二跳缺失，所以链条不闭合”。
- 规则应用结果：如“当前事实已满足 R3”“该规则不适用于本案”。
- 竞争解释淘汰：如“另一个解释已经无法成立”。
- 格式制造难度：如强制多层编号、表格矩阵、固定标签，但推理关系没有变难。

不合格：

代码块

1 请说明为什么现有材料不能确认两段记录属于同一车辆。

合格：

代码块

1 根据两段记录、题内通行参数和相似车辆记录，判断能否确认两段记录属于同一车辆，并说明依据。

4.3 难度来自哪里

难度只能来自目标推理：身份冲突、路径约束、时间窗、来源可靠性、竞争解释、规则适用范围、程序不变量、区间与阈值关系等。

不要通过题目变长、实体变多、小问变多、格式更复杂来制造难度。无关事实可以作为少量干扰，但必须能说明它为什么检验目标能力；不能加入装饰性背景。

4.4 受控合成怎么写

受控合成允许补题内人物、实体、动作、路径、局部参数、观察记录和竞争解释。它们必须明确属于当前题目或假设案例，且服务算子槽位。

受控合成不得补造真实法规、真实专业阈值、真实机构规则、真实外部记录、真实案件事实或业务结论。

合格：

代码块

1 本题设定：园区东门到北门最快通行时间为 8 分钟。

不合格：

代码块根据真实警务规范，东门到北门最快通行时间为 8 分钟。

5. OperatorPromptSpec 修改要求

每个算子文件继续保留 `OperatorPromptSpec`。字段含义按下表执行：

字段 | 写什么 | 不写什么

goal | 隐藏能力目标 | 自然题面问法、答案方向

required_question_shape | 一个中性业务任务 | “为什么不能” “最高支持到” 等答案提示

question_construction | 公开事实如何组织 | 正确推理步骤、事实角色

competitive_structure | 竞争解释如何存活 | 哪个解释正确、哪个解释被淘汰

forbidden_shortcuts | 本算子常见泄漏句式 | 泛泛写 “不要泄漏”

content_controls | 正例、负例、消融、交换、信息量平衡 | 只写抽象原则

semantic_economy | 删除冗余、不删可答事实 | 用缩短题目代替治理

结构算子可以有多个内部语义轴，但题面不能把它们拆成多个独立作答任务。内部可以检查路径、时间、身份和来源，题面只保留一个自然判断。

6. operator_execution_contracts.py 编写要求

6.1 每个契约必须包含

每个 O10-O33 算子都要有执行契约，至少包含：

代码块

```
1  {"operator_id": "O22_path_topology_joint_reachability", "supported_modes":  
    ["source_faithful", "controlled_synthesis",  
     "hypothetical_adaptation"], "primary_axis": "路径拓扑、时间窗与端点身份联合可  
    达", "allowed_auxiliary_axes": ["时间窗", "通行限制"], "required_slots": ["路径连  
    接", "通行约束", "端点观测", "时间窗", "目标位置"], "synthesizable_slots": ["题内假设  
    路径连接", "题内假设通行耗时", "题内假设端点观测"], "non_synthesizable_slots": ["真实  
    道路规则", "真实专业阈值", "真实外部记录", "真实案件结论"], "neutral_task_intent": "判  
    断目标是否可能按现有材料到达指定位置，并说明依据", "required_checks": ["决定性边消融",  
     "旁支边负例", "节点名称交换"], "requires_live_competitor":  
    true, "generates_question": true}
```

6.2 槽位写法

- `required_slots`：算子完成题目所需的材料类型。
- `synthesizable_slots`：在题内假设或受控合成模式下可以补齐的材料。

- `non_synthesizable_slots`：任何模式下都不能编造的真实外部材料。

不要默认把所有 `required_slots` 都写成 `non_synthesizable_slots`。否则虽然契约写了支持 `controlled_synthesis` 或 `hypothetical_adaptation`，实际运行会退化成只允许重组来源事实。

正确拆法：

代码块

- 1 `required_slots`：路径连接、通行约束、端点观测、时间窗。
- 2 `synthesizable_slots`：题内假设路径、题内通行耗时、题内端点记录。
- 3 `non_synthesizable_slots`：真实道路规则、真实警务规范、真实外部记录。

6.3 O14 契约

O14 必须写明：

- `generates_question = false`；
- 只参与信息闭包校验；
- 不进入任何生成候选；
- 不写自然题面；
- 检查每条题面事实是否来自来源事实、受控假设事实或题内规则。

O14 发现风险时输出可定位证据。是否重试、复核或继续真实运行，由流程机制决定，不能由 O14 内容规则直接阻断主链。

7. 题面编写器输出要求

题面编写器新生成结果只允许输出：

代码块

- 1 `{"evolved_prompt": "最终题面", "used_fact_ids": ["F01", "F02"], "surface_notes": "只说明题面如何组织公开事实，不解释答案"}`

不得继续输出或新写入：

- `expected_qwen_failure`
- `expected_evaluation_focus`
- `target_subclaim`
- `boundary_hypothesis`
- `answer_key`

- `answer_rationale`
- `decisive_fact_ids`
- 其他答案、评分、目标错误、事实角色或评分器意图字段

历史数据可以兼容读取旧字段，但题面编写器不能再生成这些字段。

8. O10-O33 单算子内容规则

算子 | 题面应该怎么写 | 常见泄漏 | 必做控制

O10 最小充分事实集 | 给同粒度事实，问业务主张是否成立及依据 | 点名最小集合或关键事实组合 | 删除任一必要事实后结论减弱；删除干扰事实后结论不变

O11 端点时序一致性 | 给端点、时间窗、路径或速度范围 | 补语言区内发生了什么；给出预计计算路径 | 约束不足时不能强行区分；交换假设名称答案不变

O12 共同必要性 | 自然呈现两个条件和组合效果 | 公开 X/Y/X+Y 标签，暗示必须共同满足 | 仅 X、仅 Y、X+Y、联合仍不足、单项冗余都要覆盖

O13 必要连接破坏 | 混合呈现同类复核事实 | 点名断点、必要连接或整体翻转 | 删除破坏事实后局部连接恢复；有替代路径时整体不自动失败

O14 信息闭包 | 不生成题面 | 重新进入生成候选 | 检查事实来源、世界一致、非法规则；只记录证据

O15 单变量变化 | 只改变一个核心事实，其余保持不变 | 同时改事实和阈值；预告翻转方向 | 前后顺序交换后语义关系一致

O16 相近解释 | 两个解释都能解释部分事实并留下残差 | 一句话排除替代解释 | 删除区分事实后两个解释重新接近；交换解释名称不变

O17 规则层级边界 | 给两个或以上职责不同的明示规则/门槛层级、版本、对象字段和当前事实 | 说明哪条规则或门槛已经适用 | 规则名称、版本、对象、边界值分别做单变量控制

O18 基线口径 | 给基线纳入条件、摘要和当前观测 | 暗示哪个基线更权威或更合适 | 交换来源名称不变；无关统计变化不变

O19 多实体绑定 | 分散呈现实体局部动作 | 直接命名实施者、协助者、受益者 | 交换实体名称不变；改变决定性行为归属才改变答案

O20 多阶段链 | 自然呈现阶段事件和状态变化 | 编号阶段、标记断点、总结完整链 | 修复真断点后答案改变；旁支事件变化不变

O21 对象来源 | 给转移、遮挡、重现和竞争来源 | 输出完整来源链或唯一编号 | 补足关键转移后增强；无识别力特征不改变答案

O22 路径可达 | 给方向边、窗口、端点和耗时 | 给预计计算路线或唯一可行提示 | 反转决定性边或改窗口后改变；旁支边不变

O23 观测可靠性 | 给距离、遮挡、采样和可见字段 | 直接写来源不可靠 | 改善决定性采集条件后增强；复制受限来源不增强

O24 多假设排序 | 多解释交叉覆盖共同事实 | 给覆盖矩阵、残差清单或排名步骤 | 增加共同覆盖事实不变；加入关键残差才改变排序

O25 程序不变量 | 给流程、字段、单位、参照和映射 | 标记错误步骤或直接说不可比 | 恢复关键映射后改变；只改记录格式不变

O26 数值阈值 | 给公式、单位、区间、误差和阈值 | 给中间计算或阈值比较结果 | 覆盖跨阈值、不跨阈值、刚好接触；无关数字不变

O27 跨层结论 | 给规则、证据事实和待判断业务主张 | 问最高支持、结论边界、为什么不能推出 | 删除局部证据只影响依赖层级，不自动翻转全部结论

O28 多跳闭合 | 给各跳原子观察，允许必要跳缺失 | 按答案顺序补完整链 | 补足唯一缺失承接后改变；旁支节点不变

O29 同一性冲突 | 混合呈现支持、连续和冲突线索 | 标记排他冲突；正确身份细节更多 | 翻转决定性冲突后归属改变；普通相似特征不自动增强

O30 主动观测 | 给竞争解释、可执行观察和资源边界 | 说明哪项最有判别力；给结果分支表 | 无论结果如何都不改变排序的观察为低价值；交换候选不变

O31 观测累积 | 给来源、时间、视角、质量和生成关系 | 标注独立、同源、重复；按条数暗示强度 | 同源复制不增强；真正独立新特征才增强

O32 关键有向边行为 | 描述局部方向性行为 | 画文字关系图；标关键边或控制者 | 删除或反转必要边改变；冗余边变化不变

O33 跨模态边界 | 给各来源字段、时间、对象和范围 | 总结共同支持什么；用来源数量暗示强度 | 未对齐材料不能叠加；不能观察目标属性的来源不增强

9. 内容测试要求

每个生成算子至少有以下测试：

1. 正例：算子适用，题面没有答案提示。
2. 槽位不足负例：缺少不可合成槽位时返回不适用或记录缺口。
3. 泄漏反例：题面写出答案方向、角色绑定、规则应用结果或完整链条时能识别。
4. 决定性事实消融：删除决定性事实后，结论减弱、无法区分或改变。
5. 无关事实消融：删除干扰事实后，答案保持不变。
6. 名称或顺序交换：实体名称、候选位置、规则名称或呈现顺序变化后，语义答案不因表面变化而改变。

测试可以是单元测试、夹具测试或离线样本压测。测试结果用于记录风险、改 prompt 和给灰度建议，不等于在线硬门禁。

10. 离线候选压测

每个生成算子建议离线抽样不少于 20 个候选。这个数字不是理论阈值，只是为了更容易发现生成波动。

20 个候选主要看六件事：

1. 是否偶发答案方向泄漏。
2. 是否退化成分步模板、表格题或格式难题。
3. 是否缺少决定性事实、干扰事实或竞争解释。
4. 是否错误合成真实规则、真实阈值或真实案件事实。
5. 是否频繁漂移到相邻算子。
6. 消融和交换检查是否稳定成立。

压测结果只能用于离线统计、风险标签和灰度建议。不能把“未跑满 20 个”或“20 个里有高风险样本”直接作为主链在线硬阻断。

11. 人工 review 清单

人工 review 每个算子时按顺序检查：

1. 题面是否只有一个用户可见业务任务。
2. 题面是否出现答案方向、规则应用结果、事实角色或推理链总结。
3. 每条事实是否来自来源事实、受控假设事实或题内规则。
4. 新增事实是否服务算子槽位，不是装饰背景。
5. 正确解释是否拥有更多细节、更权威来源或更谨慎措辞。
6. `OperatorPromptSpec` 是否只描述内容目标，不承担路由、授权、评分职责。
7. `operator_execution_contracts.py` 是否区分 `required_slots`、`synthesizable_slots` 和 `non_synthesizable_slots`。
8. O14 是否仍然不生成题。

12. 实施步骤

第一步：建立 O10-O33 内容基线

- 扫描每个 `OperatorPromptSpec`。
- 对每个算子记录是否存在六类问题：答案方向问法、完整链条总结、角色预绑定、规则应用结果、竞争解释淘汰、格式复杂度制造难度。
- O10-O33 必须全部进入清单，不能只检查已暴露问题的 O27、O28、O31。

第二步：新增或修正 `operator_execution_contracts.py`

- 覆盖 O10-O33。
- 不写自然题面，只写材料需求和控制检查。
- 不要把所有 `required_slots` 默认设为不可合成。
- O14 明确不生成题面，只参与信息闭包校验。

第三步：收紧 `prompts/operators/base.py`

- 题面编写器输入只保留公开事实、中性任务和表面写作规则。
- 新输出只允许 `evolved_prompt`、`used_fact_ids`、`surface_notes`。
- 历史字段可以兼容读取，但不能由题面编写器继续生成。

第四步：分组修订算子

- 先修 O10-O18，并确认 O14 不生成题。
- 再修 O19-O27。
- 最后修 O28-O33。
- 每个算子补齐 `goal`、`required_question_shape`、`forbidden_shortcuts`、`content_controls`。

第五步：补测试

- 为每个生成算子补正例、槽位不足负例、泄漏反例、决定性事实消融、无关事实消融、名称或顺序交换。
- 如果旧测试依赖答案侧字段，更新测试期望或增加兼容读取，不要把答案侧字段恢复给题面编写器。

第六步：运行相关测试

优先运行算子 prompt、算子内容、执行契约、O14、路由卡生成相关测试。测试失败时先判断是内容治理问题还是流程机制缺失，不要把流程机制工作塞进本任务。

13. 禁止事项

1. 不改 `collect_answers.py`、`gen_rubric.py`、`scoring.py` 的运行顺序。
2. 不把参考答案重建、Rubric 重建、弱模型回答、评分或效果确认塞进算子内容治理任务。
3. 不让 O14 回到生成候选。
4. 不用“缩短题目”代替语义泄漏治理。
5. 不把真实法规、真实专业阈值、真实机构规则、真实外部记录或真实案件结论写成可合成事实。
6. 不把离线压测、人工 review 或内容风险标签直接变成在线硬阻断。

14. 完成标准

满足以下条件后，算子内容治理可以进入机制联调：

- O10-O33 全部完成内容 review。
- O14 保持不生成独立题面。
- 每个生成算子都有 `OperatorPromptSpec` 和执行契约。
- 每个生成算子都有正例、负例、泄漏反例和控制测试。
- 题面编写器新输出不包含答案、评分标准、目标错误、事实角色或评分器意图。
- 人工抽查题面时，看不到“最高支持”“不能直接认定”“缺少第几跳”“关键证据”等答案提示。
- 离线压测结果以风险统计和灰度建议形式记录，不作为默认在线阻断。