

# 算子内容治理实施计划

## 算子内容治理实施计划

### Prompt：算子内容治理实施

代码块

```
1  你是 Question Evolution 项目的实现 agent。当前任务是实施《27_规则基准拆分0731-算子内容治理实施计划》。
2
3  实施前先阅读：
4
5  0. 项目根目录下的《全局规则约束》
6
7  1. 归档目录下的《问题进化规则约束问题》
8  2. 归档目录下的《题面信息职责隔离与全算子语义泄漏治理优化方案》
9  3. 归档目录下的《问题进化规则约束完整修改实施方案》
10 4. 父目录下的《27_规则基准拆分0731-算子内容治理实施计划》
11 5. 父目录下的《28_规则基准拆分0731-流程机制治理实施计划》
12
13 本任务只允许修改算子内容治理相关内容。不要实现路由、评分、参考答案重建、评分标准重建、候选分流、经验库写入和运行顺序改造；这些属于流程机制治理任务。
14
15 目标：
16
17 1. 让 010-033 每个算子都有清晰的题面生成规则。
18 2. 删除题面中的答案方向、推理链总结、事实角色提示、规则应用结果和竞争解释淘汰提示。
19 3. 保证 014 只作为信息闭包校验原则，不生成独立题面。
20 4. 为每个生成算子补齐执行契约和内容测试。
21 5. 保证内容测试和离线压测只产出风险统计、灰度建议和优化依据，不作为在线硬阻断。
22
23 重点修改对象：
24
25 1. `prompts/operators/base.py`
26 2. `prompts/operators/010...033`
27 3. `operator_execution_contracts.py`
28 4. 与算子内容契约相关的测试文件
29
30 实施步骤：
31
32 第一步，建立算子内容基线。
33
```

34 - 扫描 010-033 的 `OperatorPromptSpec`。

35 - 列出每个算子当前是否存在以下问题：答案方向问法、完整链条总结、角色预绑定、规则应用结果、竞争解释淘汰、格式复杂度制造难度。

36 - 不要只检查 027、028、031；010-033 都必须进入清单。

37

38 第二步，新增 `operator\_execution\_contracts.py`。

39

40 - 为每个算子提供执行契约。

41 - 每个契约至少包含：`operator\_id`、`supported\_modes`、`primary\_axis`、  
`allowed\_auxiliary\_axes`、`required\_slots`、`synthesizable\_slots`、  
`non\_synthesizable\_slots`、`neutral\_task\_intent`、`required\_checks`、  
`requires\_live\_competitor`。

42 - `required\_slots` 不得默认全部写入 `non\_synthesizable\_slots`；题内人物、实体、动作、路径、局部参数、观察记录和竞争解释可以在授权模式下作为可合成槽位。

43 - `non\_synthesizable\_slots` 只写真实法规、真实专业阈值、真实机构规则、真实外部记录、真实案件事实和业务结论等不可编造内容。

44 - 该文件只描述算子需要什么材料，不写自然题面。

45 - 014 的契约必须明确：不生成题面，只参与信息闭包校验。

46

47 第三步，收紧 `prompts/operators/base.py` 的输出要求。

48

49 - 题面编写器最终只允许输出 `evolved\_prompt`、`used\_fact\_ids`、`surface\_notes`。

50 - 删除或隔离 `expected\_qwen\_failure`、`expected\_evaluation\_focus`、  
`target\_subclaim`、`boundary\_hypothesis`、答案提示类字段。

51 - 保留必要的历史兼容读取，但新生成结果不能继续写入答案侧字段。

52

53 第四步，按组修订算子文件。

54

55 - 先修 010-018，确认 014 不生成题面。

56 - 再修 019-027。

57 - 最后修 028-033。

58 - 每个算子的 `goal` 只描述隐藏能力目标。

59 - 每个算子的 `required\_question\_shape` 必须是中性问法，只保留一个用户可见业务任务；内部可以包含多个服务同一任务的事实关系和辅助推理点。

60 - 每个算子的 `forbidden\_shortcuts` 必须列出该算子最常见泄漏形式。

61 - 每个算子的 `content\_controls` 必须包含决定性事实消融、无关事实消融、名称交换或顺序交换中适用的检查。

62

63 第五步，为每个算子补测试。

64

65 至少覆盖：

66

67 - 正例：算子适用且题面无泄漏。

68 - 负例：算子不适用或槽位不足。

69 - 泄漏反例：题面直接写出答案方向、角色绑定、规则应用或完整链条。

70 - 决定性事实消融：删除决定性事实后结论减弱、无法区分或改变。

71 - 无关事实消融：删除干扰事实后答案保持不变。

- 72 - 名称交换或顺序交换：答案不应因名称、位置、顺序变化。
- 73
- 74 第六步，运行相关测试和离线压测。
- 75
- 76 - 每个生成算子建议离线抽样不少于 20 个候选，用于观察答案泄漏、格式伪难、槽位缺失、非法合成和相邻算子漂移。
- 77 - 20 个候选不是理论阈值；压测结果写入风险统计、灰度建议和后续优化，不得直接变成在线硬阻断。
- 78
- 79 第七步，运行相关测试。
- 80
- 81 - 优先运行算子 prompt、算子内容、算子路由卡生成相关测试。
- 82 - 如果新增测试文件，文件名要清楚表达测试目标。
- 83 - 如果现有测试因旧字段依赖失败，只允许增加兼容层或更新测试期望，不要恢复答案侧字段进入题面编写器。
- 84
- 85 禁止事项：
- 86
- 87 1. 不要改 `collect\_answers.py`、`gen\_rubric.py`、`scoring.py` 的运行顺序。
- 88 2. 不要把参考答案重建、评分标准重建或效果确认塞进算子任务。
- 89 3. 不要让 014 回到生成候选。
- 90 4. 不要用“缩短题目”代替语义泄漏治理。
- 91 5. 不要把真实法规、真实专业阈值、真实机构规则、真实外部记录、真实案件事实或业务结论写成可合成事实。
- 92 6. 不要把内容风险、人工 review 或离线压测结果直接包装成自然路由硬阻断。
- 93
- 94 验收标准：
- 95
- 96 1. 010-033 全部完成内容审查和必要修改。
- 97 2. 014 保持不生成独立题面。
- 98 3. 每个生成算子都有执行契约。
- 99 4. 每个生成算子都有正例、负例、泄漏反例和控制测试。
- 100 5. 题面编写器输出不包含答案、评分标准、目标错误、事实角色或评分器意图。
- 101 6. 离线压测结果只作为风险统计和灰度建议，不默认阻断主链。
- 102 7. 人工抽查题面时，看不到“最高支持”“不能直接认定”“缺少第几跳”“关键证据”等答案提示。
- 103
- 104 完成后输出实施报告：
- 105
- 106 1. 修改了哪些算子。
- 107 2. 每个算子修复了哪类泄漏。
- 108 3. 新增或修改了哪些测试。
- 109 4. 哪些测试已运行，结果如何。
- 110 5. 哪些算子建议灰度、继续 forced qualification 或优先人工复核，并说明依据。

## 1. 文档定位

本文只负责 O10-O33 的题面内容治理：每个算子应生成什么题面、哪些话不能写进题面、需要哪些槽位和内容测试。

本文不负责路由、候选分流、参考答案重建、Rubric 重建、弱模型回答、评分、经验库写入和运行顺序。这些属于流程机制治理任务。

本文必须服从 **全局规则约束**：内容检查只能记录风险和改进建议，不能把“疑似泄漏、疑似伪难、疑似竞争不足、疑似信息不闭合”默认变成在线硬阻断。

## 2. 读者和目标

读者是后续实现 agent 和人工 reviewer。读完后应能完成四件事：

- 1. 修改 O10-O33 的 `OperatorPromptSpec`，让题面问法保持中性。
- 2. 编写 `operator_execution_contracts.py`，说明每个算子需要哪些材料。
- 3. 补齐每个生成算子的正例、负例、泄漏反例和控制测试。
- 4. 人工抽查题面时，能判断题面是否把答案方向或推理链提前写出。

## 3. 与流程机制的边界

| 事项     | 本方案负责                       | 流程机制负责                |
|--------|-----------------------------|-----------------------|
| 算子题面规则 | 写清每个算子允许和禁止的题面内容            | 读取规则并组织生成流程           |
| 算子槽位   | 说明每个算子需要哪些材料，哪些可题内合成，哪些不可合成 | 判断当前样本和模式是否满足槽位       |
| 内容测试   | 定义正例、负例、泄漏反例、消融和交换检查        | 执行测试、统计结果、决定重试或探索     |
| O14    | 定义为信息闭包校验原则，不生成题面           | 从生成候选中排除，并接入校验链       |
| 质量压测   | 定义离线压测口径                    | 选择是否灰度、重试、人工复核或继续真实运行 |

## 4. 内容治理总规则

### 4.1 题面只能写什么

- 可观察事实：时间、地点、动作、对象、记录、数值、画面条件。
- 题内明确给出的规则、公式、单位、局部参数。

- 竞争解释所需的对称事实。
- 一个用户可见的业务判断任务。

“一个用户可见任务”不是“只能有一个推理点”。例如，路径题可以同时包含时间窗、端点、路径约束和竞争车辆，但题面只问：“能否认定两段记录属于同一车辆，并说明依据。”

## 4.2 题面不能写什么

- 答案方向：如“不能直接认定”“最高只能支持”“为什么不成立”。
- 事实角色：如“关键证据是”“决定性事实是”“干扰事实是”。
- 推理链总结：如“第一跳成立、第二跳缺失，所以链条不闭合”。
- 规则应用结果：如“当前事实已满足 R3”“该规则不适用于本案”。
- 竞争解释淘汰：如“另一个解释已经无法成立”。
- 格式制造难度：如强制多层编号、表格矩阵、固定标签，但推理关系没有变难。

不合格：

代码块

1 请说明为什么现有材料不能确认两段记录属于同一车辆。

合格：

代码块

1 根据两段记录、题内通行参数和相似车辆记录，判断能否确认两段记录属于同一车辆，并说明依据。

## 4.3 难度来自哪里

难度只能来自目标推理：身份冲突、路径约束、时间窗、来源可靠性、竞争解释、规则适用范围、程序不变量、区间与阈值关系等。

不要通过题目变长、实体变多、小问变多、格式更复杂来制造难度。无关事实可以作为少量干扰，但必须能说明它为什么检验目标能力；不能加入装饰性背景。

## 4.4 受控合成怎么写

受控合成允许补题内人物、实体、动作、路径、局部参数、观察记录和竞争解释。它们必须明确属于当前题目或假设案例，且服务算子槽位。

受控合成不得补造真实法规、真实专业阈值、真实机构规则、真实外部记录、真实案件事实或业务结论。

合格：

代码块

1 本题设定：园区东门到北门最快通行时间为 8 分钟。

不合格：

代码块

1 根据真实警务规范，东门到北门最快通行时间为 8 分钟。

5. OperatorPromptSpec 修改要求

每个算子文件继续保留 OperatorPromptSpec 。字段含义按下表执行：

| 字段                      | 写什么               | 不写什么                  |
|-------------------------|-------------------|-----------------------|
| goal                    | 隐藏能力目标            | 自然题面问法、答案方向           |
| required_question_shape | 一个中性业务任务          | “为什么不能” “最高支持到” 等答案提示 |
| question_construction   | 公开事实如何组织          | 正确推理步骤、事实角色           |
| competitive_structure   | 竞争解释如何存活          | 哪个解释正确、哪个解释被淘汰        |
| forbidden_shortcuts     | 本算子常见泄漏句式         | 泛泛写 “不要泄漏”            |
| content_controls        | 正例、负例、消融、交换、信息量平衡 | 只写抽象原则                |
| semantic_economy        | 删除冗余，不删可答事实       | 用缩短题目代替治理             |

结构算子可以有多个内部语义轴，但题面不能把它们拆成多个独立作答任务。内部可以检查路径、时间、身份和来源，题面只保留一个自然判断。

6. operator\_execution\_contracts.py 编写要求

6.1 每个契约必须包含

每个 O10-O33 算子都要有执行契约，至少包含：

代码块

```
1  {"operator_id": "022_path_topology_joint_reachability", "supported_modes":  
   ["source_faithful", "controlled_synthesis",  
    "hypothetical_adaptation"], "primary_axis": "路径拓扑、时间窗与端点身份联合可  
   达", "allowed_auxiliary_axes": ["时间窗", "通行限制"], "required_slots": ["路径连  
   接", "通行约束", "端点观测", "时间窗", "目标位置"], "synthesizable_slots": ["题内假设  
   路径连接", "题内假设通行耗时", "题内假设端点观测"], "non_synthesizable_slots": ["真实  
   道路规则", "真实专业阈值", "真实外部记录", "真实案件结论"], "neutral_task_intent": "判  
   断目标是否可能按现有材料到达指定位置，并说明依据", "required_checks": ["决定性边消融",  
   "旁支边负例", "节点名称交换"], "requires_live_competitor":  
   true, "generates_question": true}
```

## 6.2 槽位写法

- `required_slots`：算子完成题目所需的材料类型。
- `synthesizable_slots`：在题内假设或受控合成模式下可以补齐的材料。
- `non_synthesizable_slots`：任何模式下都不能编造的真实外部材料。

不要默认把所有 `required_slots` 都写成 `non_synthesizable_slots`。否则虽然契约写了支持 `controlled_synthesis` 或 `hypothetical_adaptation`，实际运行会退化成只允许重组来源事实。

正确拆法：

代码块

```
1  required_slots: 路径连接、通行约束、端点观测、时间窗。  
2  synthesizable_slots: 题内假设路径、题内通行耗时、题内端点记录。  
3  non_synthesizable_slots: 真实道路规则、真实警务规范、真实外部记录。
```

## 6.3 O14 契约

O14 必须写明：

- `generates_question = false`；
- 只参与信息闭包校验；
- 不进入任何生成候选；
- 不写自然题面；
- 检查每条题面事实是否来自来源事实、受控假设事实或题内规则。

O14 发现风险时输出可定位证据。是否重试、复核或继续真实运行，由流程机制决定，不能由 O14 内容规则直接阻断主链。

## 7. 题面编写器输出要求

题面编写器新生成结果只允许输出：

代码块

```
1  {"evolved_prompt": "最终题面", "used_fact_ids": ["F01", "F02"], "surface_notes":  
   "只说明题面如何组织公开事实，不解释答案"}
```

不得继续输出或新写入：

- expected\_qwen\_failure
- expected\_evaluation\_focus
- target\_subclaim
- boundary\_hypothesis
- answer\_key
- answer\_rationale
- decisive\_fact\_ids
- 其他答案、评分、目标错误、事实角色或评分器意图字段

历史数据可以兼容读取旧字段，但题面编写器不能再生成这些字段。

## 8. 010-033 单算子内容规则



| 算子          | 题面应怎么写                            | 常见泄漏                   | 必做控制                        |
|-------------|-----------------------------------|------------------------|-----------------------------|
| O10 最小充分事实集 | 给同粒度事实，问业务主张是否成立及依据               | 点名最小集合或关键事实组合          | 删除任一必要事实后结论减弱；删除干扰事实后结论不变   |
| O11 端点时序一致性 | 给端点、时间窗、路径或速度范围                   | 补造盲区内发生了什么；给出预计算路径     | 约束不足时不能强行区分；交换假设名称答案不变      |
| O12 共同必要性   | 自然呈现两个条件和组合效果                     | 公开 X/Y/X+Y 标签；暗示必须共同满足 | 仅 X、仅 Y、X+Y、联合仍不足、单项冗余都要覆盖  |
| O13 必要连接破坏  | 混合呈现同类复核事实                        | 点名断点、必要连接或整体翻转         | 删除破坏事实后局部连接恢复；有替代路径时整体不自动失败 |
| O14 信息闭包    | 不生成题面                             | 重新进入生成候选               | 检查事实来源、世界一致、非法规则；只记录证据      |
| O15 单变量变化   | 只改变一个核心事实，其余保持不变                  | 同时改事实和阈值；预告翻转方向        | 前后顺序交换后语义关系一致               |
| O16 相近解释    | 两个解释都能解释部分事实并留下残差                 | 一句话排除替代解释              | 删除区分事实后两个解释重新接近；交换解释名称不变    |
| O17 规则层级边界  | 给两个或以上职责不同的明示规则/门槛层级、版本、对象字段和当前事实 | 说明哪条规则或门槛已经适用          | 规则名称、版本、对象、边界值分别做单变量控制      |
| O18 基线口径    | 给基线纳入条件、摘要和当前观测                   | 暗示哪个基线更权威或更合适          | 交换来源名称不变；无关统计变化不变           |
| O19 多实体绑定   | 分散呈现实体局部动作                        | 直接命名实施者、协助者、受益者        | 交换实体名称不变；改变决定性行为归属才改变答案     |
| O20 多阶段链    | 自然呈现阶段事件和状态变化                     | 编号阶段、标记断点、总结完整链        | 修复真断点后答案改变；旁支事件变化不变         |
| O21 对象来源    | 给转移、遮挡、重现和竞争来源                    | 输出完整来源链或唯一编号           | 补足关键转移后增强；无识别力特征不改变答案       |
| O22 路径可达    | 给方向边、窗口、端点和耗时                     | 给预计算路线或唯一可行提示          | 反转决定性边或改窗口后改变；              |

|           |                   |                    |                            |
|-----------|-------------------|--------------------|----------------------------|
|           |                   |                    | 旁支边不变                      |
| O23 观测可靠性 | 给距离、遮挡、采样和可见字段    | 直接写来源不可靠           | 改善决定性采集条件后可增强；复制受限来源不增强    |
| O24 多假设排序 | 多解释交叉覆盖共同事实       | 给覆盖矩阵、残差清单或排名步骤    | 增加共同覆盖事实不变；加入关键残差才改变排序     |
| O25 程序不变量 | 给流程、字段、单位、参照和映射   | 标记错误步骤或直接说不可比      | 恢复关键映射后改变；只改记录格式不变         |
| O26 数值阈值  | 给公式、单位、区间、误差和阈值   | 给中间计算或阈值比较结果       | 覆盖跨阈值、不跨阈值、刚好接触；无关数字不变     |
| O27 跨层结论  | 给规则、证据事实和待判断业务主张  | 问最高支持、结论边界、为什么不能推出 | 删除局部证据只影响依赖层级，不自动翻转全部结论    |
| O28 多跳闭合  | 给各跳原子观察，允许必要跳缺失   | 按答案顺序补完整链          | 补足唯一缺失承接后改变；旁支节点不变         |
| O29 同一性冲突 | 混合呈现支持、连续和冲突线索    | 标记排他冲突；正确身份细节更多    | 翻转决定性冲突后归属改变；普通相似特征不自动增强   |
| O30 主动观测  | 给竞争解释、可执行观察和资源边界  | 说明哪项最有判别力；给结果分支表   | 无论结果如何都不改变排序的观察为低价值；交换候选不变 |
| O31 观测累积  | 给来源、时间、视角、质量和生成关系 | 标注独立、同源、重复；按条数暗示强度 | 同源复制不增强；真正独立新特征才增强         |
| O32 关键有向边 | 描述局部方向性行为         | 画文字关系图；标关键边或控制者    | 删除或反转必要边改变；冗余边变化不变         |
| O33 跨模态边界 | 给各来源字段、时间、对象和范围   | 总结共同支持什么；用来源数量暗示强度 | 未对齐材料不能叠加；不能观察目标属性的来源不增强   |

9. 内容测试要求

每个生成算子至少有以下测试：

- 1. 正例：算子适用，题面没有答案提示。
- 2. 槽位不足负例：缺少不可合成槽位时返回不适用或记录缺口。
- 3. 泄漏反例：题面写出答案方向、角色绑定、规则应用结果或完整链条时能识别。

4. 决定性事实消融：删除决定性事实后，结论减弱、无法区分或改变。
5. 无关事实消融：删除干扰事实后，答案保持不变。
6. 名称或顺序交换：实体名称、候选位置、规则名称或呈现顺序变化后，语义答案不因表面变化而改变。

测试可以是单元测试、夹具测试或离线样本压测。测试结果用于记录风险、改 prompt 和给灰度建议，不等于在线硬门禁。

## 10. 离线候选压测

每个生成算子建议离线抽样不少于 20 个候选。这个数字不是理论阈值，只是为了更容易发现生成波动。

20 个候选主要看六件事：

1. 是否偶发答案方向泄漏。
2. 是否退化成分步模板、表格题或格式难题。
3. 是否缺少决定性事实、干扰事实或竞争解释。
4. 是否错误合成真实规则、真实阈值或真实案件事实。
5. 是否频繁漂移到相邻算子。
6. 消融和交换检查是否稳定成立。

压测结果只能用于离线统计、风险标签和灰度建议。不能把“未跑满 20 个”或“20 个里有高风险样本”直接作为主链在线硬阻断。

## 11. 人工 review 清单

人工 review 每个算子时按顺序检查：

1. 题面是否只有一个用户可见业务任务。
2. 题面是否出现答案方向、规则应用结果、事实角色或推理链总结。
3. 每条事实是否来自来源事实、受控假设事实或题内规则。
4. 新增事实是否服务算子槽位，不是装饰背景。
5. 正确解释是否拥有更多细节、更权威来源或更谨慎措辞。
6. `OperatorPromptSpec` 是否只描述内容目标，不承担路由、授权、评分职责。
7. `operator_execution_contracts.py` 是否区分 `required_slots`、`synthesizable_slots` 和 `non_synthesizable_slots`。
8. O14 是否仍然不生成题。

## 12. 实施步骤

## 第一步：建立 O10-O33 内容基线

- 扫描每个 `OperatorPromptSpec`。
- 对每个算子记录是否存在六类问题：答案方向问法、完整链条总结、角色预绑定、规则应用结果、竞争解释淘汰、格式复杂度制造难度。
- O10-O33 必须全部进入清单，不能只检查已暴露问题的 O27、O28、O31。

## 第二步：新增或修正 `operator_execution_contracts.py`

- 覆盖 O10-O33。
- 不写自然题面，只写材料需求和控制检查。
- 不要把所有 `required_slots` 默认设为不可合成。
- O14 明确不生成题面，只参与信息闭包校验。

## 第三步：收紧 `prompts/operators/base.py`

- 题面编写器输入只保留公开事实、中性任务和表面写作规则。
- 新输出只允许 `evolved_prompt`、`used_fact_ids`、`surface_notes`。
- 历史字段可以兼容读取，但不能由题面编写器继续生成。

## 第四步：分组修订算子

- 先修 O10-O18，并确认 O14 不生成题。
- 再修 O19-O27。
- 最后修 O28-O33。
- 每个算子补齐 `goal`、`required_question_shape`、`forbidden_shortcuts`、`content_controls`。

## 第五步：补测试

- 为每个生成算子补正例、槽位不足负例、泄漏反例、决定性事实消融、无关事实消融、名称或顺序交换。
- 如果旧测试依赖答案侧字段，更新测试期望或增加兼容读取，不要把答案侧字段恢复给题面编写器。

## 第六步：运行相关测试

优先运行算子 prompt、算子内容、执行契约、O14、路由卡生成相关测试。测试失败时先判断是内容治理问题还是流程机制缺失，不要把流程机制工作塞进本任务。

## 13. 禁止事项

1. 不改 `collect_answers.py`、`gen_rubric.py`、`scoring.py` 的运行顺序。
2. 不把参考答案重建、Rubric 重建、弱模型回答、评分或效果确认塞进算子内容治理任务。
3. 不让 O14 回到生成候选。
4. 不用“缩短题目”代替语义泄漏治理。
5. 不把真实法规、真实专业阈值、真实机构规则、真实外部记录或真实案件结论写成可合成事实。
6. 不把离线压测、人工 review 或内容风险标签直接变成在线硬阻断。

## 14. 完成标准

满足以下条件后，算子内容治理可以进入机制联调：

- O10-O33 全部完成内容 review。
- O14 保持不生成独立题面。
- 每个生成算子都有 `OperatorPromptSpec` 和执行契约。
- 每个生成算子都有正例、负例、泄漏反例和控制测试。
- 题面编写器新输出不包含答案、评分标准、目标错误、事实角色或评分器意图。
- 人工抽查题面时，看不到“最高支持”“不能直接认定”“缺少第几跳”“关键证据”等答案提示。
- 离线压测结果以风险统计和灰度建议形式记录，不作为默认在线阻断。