

阶段 2：Session 与 Planner 增强实施计划

阶段 2：Session 与 Planner 增强实施计划

状态：Proposed

前置阶段：阶段 1 受控 Agent 外壳

目标读者：实现 Agent Session、Planner 和状态恢复的工程师

读完后应能做的事：在初版 Agent 外壳上实现可恢复 Session、多版本计划和受约束 Planner。

1. 阶段目标

阶段 1 的 Agent 以一次 `AgentTask` 运行为中心，已经能规划、调用工具、观察产物和输出报告。阶段 2 要把“一次运行”升级为“一个可恢复、可审计、可多次观察和重规划的 Agent Session”。

本阶段只增强控制层状态与计划，不拆现有业务流水线。

2. 范围

本阶段实现：

- Agent Session 生命周期。
- Session Manifest 和状态机。
- Plan Revision。
- 三层计划：任务计划、轮次计划、恢复计划。
- Plan Step 契约增强。
- Plan Validator。
- 预算、终止原因和人工复核门槛。

本阶段不实现：

- 原子化拆分现有业务工具。
- active 全局 Memory。
- Global Judge 自动发布。
- 多 Agent 协作。

3. 目标状态

阶段完成后，每个 Agent 任务都有一个独立 Session。Session 负责保存目标、预算、当前计划版本、当前步骤、真实实验目录、最近观察、终止原因和恢复点。

Planner 不再只生成简单工具顺序，而是输出结构化 Plan Step。每个 Step 都必须声明工具、参数、前置条件、预期产物、成功条件、业务失败处理、系统失败处理和预算限制。

4. 核心契约

4.1 Session Manifest

Session Manifest 至少包含：

代码块

```
1  {"session_id": "agent-20260805-001", "root_goal": "找到高可信降分边界候  
   选", "status": "planned", "plan_revision": 1, "current_step_id":  
   "step_check_environment", "current_plan_path": "agent_runs/2026-08-05/agent-  
   20260805-001/plans/plan_r001.json", "latest_observation_path": "agent_runs/2026-  
   08-05/agent-20260805-001/agent_observation.json", "event_log_path":  
   "agent_runs/2026-08-05/agent-20260805-001/agent_events.jsonl", "agent_run_dir":  
   "agent_runs/2026-08-05/agent-20260805-001", "experiment_dir": "experiments/2026-  
   08-05/exp1", "budgets": {"max_search_steps": 25, "boundary_target":  
   5}, "terminal_reason": null, "requires_manual_review":  
   false, "manual_review_status": null, "resume_checkpoint": {"resume_exp_dir":  
   "experiments/2026-08-05/exp1", "resume_start_round":  
   null, "last_completed_step_id": null}}
```

4.2 Session 状态

状态限定为：

代码块

```
1  created  
2  context_ready  
3  planned  
4  executing  
5  observing  
6  replanning  
7  suspended  
8  completed  
9  stopped  
10 blocked  
11 failed
```

`manual_review_required` 不属于 Session `status` 枚举。它表示自动流程已经暂停，等待人工复核，应写入 `terminal_reason` 或暂停原因字段。缺少人工复核时，Session Manifest 使用：

```
1 代码块{"status": "suspended", "terminal_reason":  
    "manual_review_required", "requires_manual_review":  
    true, "manual_review_status": "pending"}
```

只有在无需人工复核，或人工复核已经明确通过且没有后续阻塞时，Session 才能写为 `completed`。

4.3 Plan Step

Plan Step 至少包含：

代码块

```
1  {"step_id": "step_run_pipeline", "intent": "启动完整多算子实验", "tool_name":  
    "run_full_loop", "arguments": {}, "preconditions":  
    ["environment_checked"], "expected_outputs": ["experiment_dir", "summary",  
    "final_scored"], "success_condition":  
    "run_loop_completed_or_recoverable_experiment_dir_found", "business_failure_acti  
on": "observe_and_report", "system_failure_action":  
    "suspend_or_block", "budget_limit": {"max_search_steps": 25}, "depends_on":  
    ["step_check_environment"]}
```

4.4 模块责任边界

- Session Manager 负责创建 Session Manifest、追加状态事件、维护当前计划版本、当前步骤、恢复点和终止原因。
- Planner 负责任务计划、轮次计划、恢复计划和只读复盘计划的结构化生成；Planner 不直接判断人工复核是否通过。
- Plan Validator 负责执行前拒绝非法计划，包括未登记工具、缺少前置产物、非法执行范围和越权修改正式资产。
- Observer 负责读取实验目录、manifest、统计摘要、候选状态和错误证据，输出结构化 observation。
- Decision 负责根据 observation、预算和工具结果决定 `stop_and_report`、`blocked`、是否需要人工复核或进入 replan；Session Manager 负责把人工复核决策落为 `suspended/manual_review_required`。
- Reporter 负责输出可审计报告，不得把自动评分候选表述为已人工确认的有效边界。

5. 实施步骤

5.1 扩展状态文件

- 将初版 `agent_run_state` 扩展为 Session Manifest。

- 保留与阶段 1 状态字段兼容。
- 任何状态变更都追加事件，不只覆盖最新状态。
- 新增字段至少包括 `terminal_reason`、`requires_manual_review`、`manual_review_status`、`current_plan_path`、`latest_observation_path`、`event_log_path` 和 `resume_checkpoint`。

5.2 实现 Plan Revision

- 每次生成新计划都递增 `plan_revision`。
- 计划文件按 revision 保存。
- 当前有效计划由 Session Manifest 指向。
- Replan 必须写明触发原因和被替换计划。

5.3 增强 Planner

- `dry-run` 生成完整 Plan Step。
- 新实验生成任务计划和轮次计划。
- 续跑生成恢复计划。
- 只读复盘生成 review plan，不触发真实运行。

5.4 增强 Plan Validator

Validator 必须拒绝：

- 未登记工具。
- 缺少必需前置产物。
- 计划绕过环境检查、manifest 校验或真实评分。
- 非法 `execution_scope`。
- 将业务失败当作系统重试。
- 计划修改正式 Prompt、Router、Rubric、Memory active 状态或算子文件。

5.5 增加预算和终止语义

- 预算耗尽要写明确 `terminal_reason`。
- `score_increased` 只触发失败处理，不可作为成功。
- 缺少人工复核时写为 `status=suspended`、`terminal_reason=manual_review_required`，不写成 `completed`。

5.6 保持阶段 1 兼容

- `agent_run_state` 采用增量扩展，旧字段继续保留，缺失的新字段按默认值读取。
- 阶段 1 的 `run`、`resume`、`review` 命令入口和主要产物路径保持可用。
- 对外报告仍输出观察、决策和工具结果；变化只体现在 Session 状态、终止原因、计划版本和恢复点更精确。
- 已有实验目录不因缺少阶段 2 字段被判定损坏；只有 manifest、正式产物或 JSON 解析失败才进入阻塞。

6. 验收标准

- 新实验、续跑、只读复盘都能生成不同类型的计划。
- 每个计划都有 revision、step、前置条件和预期产物。
- 非法计划在执行前被拒绝。
- 中断后可以从 Session Manifest 判断当前步骤和真实实验目录。
- 需要人工复核的结果写为 `suspended/manual_review_required`，不会写成 `completed`。
- 阶段 1 的 run/resume/review 行为保持可用。

7. 后续衔接

阶段 2 完成后，阶段 3 可以基于稳定的 Plan Step 和 Session 状态实现更严格的工具契约、执行器和 Observation 标准化。