

阶段 3：Tool、Executor 与 Observation 实施计划

阶段 3：Tool、Executor 与 Observation 实施计划

状态：Proposed

前置阶段：阶段 1、阶段 2

目标读者：实现工具契约、执行器、调度和观察标准化的工程师

读完后应能做的事：把 Agent 对现有流水线的调用从简单 subprocess 包装升级为可验证、可恢复、可审计的执行层。

1. 阶段目标

阶段 3 解决“Agent 如何可靠调用领域能力，并把结果转成统一观察”的问题。它不要求把现有流水线所有内部步骤拆成原子工具，但必须让复合工具有稳定契约、事件、预算、失败分类和 Observation 输出。

2. 范围

本阶段实现：

- Tool Registry 元数据。
- Tool Call / Tool Result 契约。
- Executor 标准执行循环。
- 业务失败和系统失败分类。
- Observation Normalizer。
- Reflector 决策规则增强。
- 工具调用 Trace、成本和耗时记录。

本阶段不实现：

- 全量原子工具拆分。
- Planner 自由调用 Shell。
- 模型驱动执行器。
- 多 Agent Scheduler。

3. Tool Registry

每个工具登记时必须声明：

阶段 3 仍以复合工具为主：`check_environment`、`run_full_loop`、`resume_full_loop`、`observe_experiment`、`write_agent_report`。后续研究模式可以逐步增加原子工具。

4. Executor 标准循环

Executor 对每个 Plan Step 执行以下流程：

代码块

```
1  读取 Step
2  -> 校验前置条件
3  -> 校验预算
4  -> 生成幂等键
5  -> 写 tool_started
6  -> 调用 Tool Registry 中的工具
7  -> 校验 return code 与正式产物
8  -> 写 tool_completed 或 tool_failed
9  -> 生成 Tool Result
10 -> 转换 Observation
11 -> 交给 Reflector / Decision Engine
```

Executor 不进行开放式推理，只执行已通过 Policy Guard 和 Plan Validator 的 Step。

5. 失败分类

5.1 业务失败

业务失败表示工具正常完成，但候选或策略没有产生目标收益，例如：

- `score_increased`
- `score_unchanged`
- `not_applicable`
- `validation_failed`
- `no_gain`
- `repeated_pattern`

业务失败不进行同条件系统重试，应进入观察、报告、切换策略或人工复核。

5.2 可重试系统错误

可重试系统错误包括：

- 网络超时。
- 服务限流。
- 临时解析失败。
- 短暂文件锁冲突。

这类错误可以有限重试，并必须记录重试次数和退避原因。

5.3 不可重试系统错误

不可重试系统错误包括：

- schema 不兼容。
- 正式输入缺失。
- manifest 损坏。
- artifact 哈希冲突。
- checkpoint 身份不匹配。

这类错误必须 Fail-fast 或进入人工处理。

6. Observation 契约

Observation 至少包含：

代码块

```
1  {"observation_id": "obs-001", "source_tool": "run_full_loop", "type":  
   "score_increased", "severity": "warning", "summary": "部分分支出现负收
```

```
益","evidence_refs": [],"metrics": {}, "recommended_actions": ["report",
"manual_review"],"requires_replan": false,"requires_human_review": true}
```

核心 Observation 类型：

代码块

- 1 environment_ready
- 2 pipeline_started
- 3 pipeline_completed
- 4 candidate_invalid
- 5 score_decreased
- 6 score_unchanged
- 7 score_increased
- 8 not_applicable
- 9 boundary_candidate_found
- 10 budget_warning
- 11 tool_retryable_failure
- 12 tool_fatal_failure
- 13 artifact_missing
- 14 manifest_corrupted
- 15 review_report_ready

7. Reflector 与决策规则

本阶段的 Reflector 仍以确定性规则为主：

8. 验收标准

- 每次工具调用都有 started/completed/failed 事件。
- Tool Result 不泄露完整 API key、完整环境变量、完整模型响应或全量 JSONL。
- 业务失败和系统失败在事件和报告中分离。

- Observation 可以从现有实验产物稳定生成。
- Executor 不执行未登记工具或未通过 Validator 的 Step。
- 阶段 1 与阶段 2 的 CLI 行为保持可用。

9. 后续衔接

阶段 3 完成后，阶段 4 可以在稳定 Observation 和 Tool Trace 基础上建设 Memory 快照、策略卡和跨实验摘要。