

阶段 5：Global Judge 与自进化治理实施计划

阶段 5：Global Judge 与自进化治理实施计划

状态：Proposed

前置阶段：阶段 1 至阶段 4

目标读者：实现离线复盘、策略 proposal、Shadow/Replay 和发布门禁的工程师

读完后应能做的事：建立不参与实时正式决策的 Global Judge 治理链路。

1. 阶段目标

阶段 5 建立离线 Global Judge。它负责跨实验复盘、失败层级诊断、策略 proposal、Shadow 策略卡和发布建议。

Global Judge 不参与当前 Session 的正式实时决策，不直接修改当前实验的正式结果，也不自动改 Prompt、Router、Rubric、算子或 active Memory。

2. 当前基础

阶段 1 已经允许只读复盘报告和 proposal 输出。阶段 4 建立 Memory Snapshot、L1 实验事实和 L2 策略卡。阶段 5 在这些证据基础上实现离线治理。

3. 实施范围

本阶段实现：

- Evidence Pack。
- 离线 Global Judge 输入输出契约。
- 失败层级诊断。
- Optimization Proposal。
- Shadow 策略卡生成。
- Replay/Holdout 验证入口。
- 发布权限和审批记录。

本阶段不实现：

- 实时 Agent 自动采纳 proposal。
- 无审批 active 发布。
- 自动改写正式 Prompt 或算子文件。

- 用单次实验结论覆盖全局策略。

4. Evidence Pack

Global Judge 的输入必须是可追溯证据包，至少包含：

- 实验配置和 Snapshot。
- 样本、节点、分支和算子结果。
- 路由和校验记录。
- 前后得分、Judge 重复结果和一致性。
- 调用成本和耗时。
- L1 实验事实 Memory。
- L2 策略卡候选。
- 人工复核结果。

Evidence Pack 只引用正式产物和摘要，不复制完整模型响应。

5. 诊断层级

Global Judge 诊断必须落到明确层级：

代码块

```
1 sample/data
2 router
3 operator selection
4 operator generation
5 validation
6 rubric/judge
7 memory
8 search/cost
```

诊断输出必须区分：

- 业务失败。
- 系统失败。
- Judge 不稳定。
- 策略冲突。
- 证据不足。

6. Proposal 契约

Optimization Proposal 至少包含：

代码块

```
1  {"proposal_id": "proposal-001", "source_evidence_pack": "evidence-pack-id", "diagnosis_level": "operator generation", "summary": "某类题型下 016 负收益率偏高", "recommended_change": "进入 shadow 观察，暂不降权", "affected_scope": {"scene_family": "...", "question_form": "...", "reasoning_mechanism": "..."}, "evidence_strength": "medium", "risk": "judge_instability_possible", "status": "proposed"}
```

允许状态：

代码块

```
1  proposed
2  needs_human_review
3  shadow
4  rejected_insufficient_evidence
```

`active` 只能由发布治理流程写入，不能由 Global Judge 单独写入。

7. Shadow 与验证

Shadow 策略只能用于旁路评估：

- 可以在报告中显示“如果采纳该策略会影响哪些路由”。
- 可以用于 Replay/Holdout 统计。
- 不能影响正式运行中的 Router、Operator Plan 或评分。

Replay/Holdout 至少检查：

- 有效率是否提升。
- `score_increased` 率是否升高。
- 无效生成率是否升高。
- Judge 分歧率是否可接受。
- 是否只适用于声明的适用条件。

8. 发布治理

发布权限必须独立于实时 Agent：

active 发布必须记录：

- 审批人或审批流程。
- Evidence Pack。
- Replay/Holdout 结果。
- 风险说明。
- 生效 Snapshot。
- 回滚条件。

9. Policy Guard 要求

Policy Guard 必须拒绝：

- Global Judge 直接修改正式 Prompt、Router、Rubric、Memory、score、state 或算子文件。
- 未经 Replay/Holdout 或人工复核的 active 发布。
- 证据不足 proposal 进入 shadow。
- Shadow 策略影响实时正式执行。
- 把自动诊断写成已确认人工结论。

10. 测试要求

- Evidence Pack 缺少 Snapshot 时拒绝运行。
- Proposal 缺少证据引用时被拒绝。
- Shadow 策略不改变正式 Router 输入。
- Global Judge 输出不会修改正式实验产物。
- active 发布无审批记录时失败。

11. 验收标准

- Global Judge 可以从 Evidence Pack 生成只读诊断报告。
- Proposal 不修改正式产物。
- Shadow 策略不会影响实时 Agent 决策。

- active 发布必须经过独立门禁。
- Global Judge 明确标记证据不足和 Judge 不稳定场景。

12. 后续衔接

阶段 5 完成后，阶段 6 可以补齐 Replay、审计、指标看板、最终输出契约和运行治理闭环。