

阶段 6：审计、回放与运行治理实施计划

阶段 6：审计、回放与运行治理实施计划

状态：Proposed

前置阶段：阶段 1 至阶段 5

目标读者：实现审计、Replay、指标和最终输出治理的工程师

读完后应能做的事：把 Agent Harness 从可运行系统补齐为可审计、可回放、可治理的长期实验平台。

1. 阶段目标

阶段 6 补齐长期运行所需的 Trace、Checkpoint、Replay、指标、最终输出契约和发布审计。

这个阶段不追求新增更强自治能力，而是确保前面阶段产生的计划、工具、观察、Memory 和 proposal 都能被复盘、验证和回滚。

2. 当前基础

阶段 1 至阶段 5 已分别建立 Agent 外壳、Session/Planner、Tool/Observation、Memory 快照和 Global Judge 治理。阶段 6 要把这些能力串成长期可运营的审计和回放体系。

3. 实施范围

本阶段实现：

- Session Trace 完整性。
- Checkpoint 与恢复审计。
- Replay 输入输出契约。
- 运行指标和质量指标。
- 最终输出契约。
- 发布记录和回滚记录。
- 长期运行 Review 清单。

本阶段不实现：

- 首版多自治 Agent 协同。
- 无监督 active 发布。
- 将 Replay 结果直接改写历史实验。

4. Trace 与 Checkpoint

每个 Session 必须能追溯：

- 任务目标和成功标准。
- 每个 Plan Revision。
- 每个 Tool Call 和 Tool Result。
- Observation 时间线。
- Memory 检索摘要。
- 预算消耗。
- Checkpoint。
- 重规划和回滚原因。
- 最终状态和 Terminal Reason。

Checkpoint 必须声明：

- 对应 Step。
- 输入 Snapshot。
- 输出 Artifact。
- manifest 状态。
- 是否可恢复。
- 恢复时禁止变化的字段。

5. Replay 契约

Replay 用于验证策略、恢复能力和发布候选，不用于改写历史正式结果。

Replay 输入：

- Session Manifest。
- Plan Revision。
- Tool Trace。
- Snapshot IDs。
- Evidence Pack。
- 候选策略或 proposal。

Replay 输出：

- replay_status。
- 与原运行的差异。

- 预算差异。
- 关键指标差异。
- 是否支持发布或退役。
- 需要人工复核的原因。

6. 指标体系

核心指标包括：

- 有效边界候选率。
- `score_increased` 率。
- 无效生成率。
- `selected_then_not_applicable` 率。
- Judge 分歧率。
- 每个边界候选的调用成本。
- 平均重规划次数。
- Checkpoint 恢复成功率。
- Memory 命中前后的收益差异。
- Exploration 的边际收益和机会成本。

指标必须能按实验、场景、题型、推理机制、算子和策略卡聚合。

7. 最终输出契约

每个根样本最终结果至少包含：

代码块

```
1  final_status
2  best_question
3  best_candidate_id
4  parent_question
5  score_before
6  score_after
7  score_delta
8  target_mechanism
9  operator_path
10 validation_summary
11 judge_stability
12 cost_summary
13 memory_refs
```

最终结果必须能追溯到计划、工具调用、候选、评分、效果分析和 Memory 记录。

8. 运行治理

长期运行时需要固定以下治理动作：

- 每批实验结束后生成审计报告。
- 每个 active 发布前必须有 Replay/Holdout 结果。
- 每个策略退役必须说明触发指标。
- 每次恢复必须记录恢复点和恢复结果。
- 每次人工复核必须保留输入、结论和影响范围。
- 每个版本发布必须能回滚到上一组 Snapshot。

9. Policy Guard 要求

Policy Guard 必须拒绝：

- Replay 改写历史正式结果。
- 没有 Trace 的 final result。
- 没有审批记录的 active 发布。
- 不带 Snapshot 的回放。
- 不可追溯的指标聚合。

10. 测试要求

- 任意 Session Trace 可以还原主要执行路径。
- final result 缺少候选或评分引用时被拒绝。
- Replay 输出不会修改历史正式产物。
- 发布记录缺少审批人或 Evidence Pack 时失败。
- Checkpoint 身份不匹配时不能恢复。

11. 验收标准

- 任意 Session 可以从 Trace 还原主要执行路径。
- 任意 final result 可以追溯到对应候选、评分和 Memory。
- Replay 不修改历史正式结果。

- 指标能暴露收益、负收益、成本和恢复质量。
- active 发布、退役和回滚都有审批记录。
- 阶段 1 至阶段 5 的边界仍被保留。

12. 后续扩展

阶段 6 完成后，才适合评估是否需要多 Agent 协作。多 Agent 如需引入，应围绕当前 Question Evolution 的角色拆分和权限边界重新设计，不能直接复用跨项目运行时方案。