

阶段 8：Agent Skills 制定实施方案

阶段 8：Agent Skills 制定实施方案

状态：Proposed
更新日期：2026-08-06
适用范围：Question Evolution Agent Harness 的可复用工作规程建设
目标读者：后续实现人员、Agent 运行维护人员、实验复盘人员
读完后应能做的事：判断哪些环节需要制定 Skill、每个 Skill 应写什么、按什么顺序落地、如何验收。

1. 结论

当前项目需要制定 Skills，但不能把每个代码模块、每个工具和每个业务算子都做成 Skill。

Skill 的定位是：**沉淀 Agent 做某类工作的稳定规程**。它告诉 Agent 在某个场景下应如何读取材料、如何分析、如何输出、哪些动作禁止做。

本阶段优先制定 10 个 Skills：

2. Skill 边界

当前项目中 Tool、Operator 和 Skill 必须分开。

- 代码块
- 1 Tool：真实执行动作，例如运行实验、观察产物、写报告。
 - 2 Operator：业务算子，例如 010-033，用于生成进化问题。

2.1 应制定 Skill 的情况

满足以下任一条件时，适合制定 Skill：

- 1. 多个 Agent 或多个阶段会重复执行同一类分析。
- 2. 分析结果会影响后续计划、记忆、报告或人工复核。
- 3. 错误表述会产生治理风险，例如把自动评分写成“已确认有效边界”。
- 4. 需要固定输入、输出、禁止事项和验收标准。
- 5. 需要给不同模型或子智能体复用同一套工作规程。

2.2 不应制定 Skill 的情况

以下内容不做 Skill：

3. Skill 文件标准

每个 Skill 必须使用统一结构，避免写成泛泛提示词。

建议结构：

代码块

```
1  # Skill 名称
2
3  ## 1. 适用场景
4  说明什么时候使用，什么时候不能使用。
5
6  ## 2. 输入材料
7  列出必须读取和可选读取的材料。
8
9  ## 3. 禁止事项
10  列出绝对不能做的动作。
11
```

```
12  ## 4. 工作步骤
13  按顺序说明 Agent 应如何分析。
14
15  ## 5. 输出结构
16  给出固定字段，便于测试和下游读取。
17
18  ## 6. 失败降级
19  说明材料缺失、证据不足、输出冲突时怎么处理。
20
21  ## 7. 验收标准
22  说明怎么判断该 Skill 执行合格。
```

所有 Skill 都必须遵守 4 条通用规则：

- 1. 没有证据引用的结论不能进入正式建议。
- 2. 自动分析不能写成已人工确认。
- 3. Skill 不能修改正式提示词、算子、评分、状态和 active Memory。
- 4. Skill 输出必须短、结构化、可审计。

3.1 Skill 与上下文分层

Skill 的输入必须说明来自 `context_pack_v2` 的哪一层，不能笼统写成“读取全部上下文”。

建议规则：

所有 Skill 输出都必须保留 `evidence_refs` 或 `artifact_refs`。如果输入上下文只提供摘要，Skill 不能把摘要改写成“已确认事实”，只能把它标为候选证据或待复核项。

4. Skill 存放与注册

建议后续新增项目内 Skill 包，并建立注册表。

建议结构：

代码块

```
1  agent_skills/
2    experiment-review-skill/SKILL.md
3    agent-report-skill/SKILL.md
```

```
4    recovery-diagnosis-skill/SKILL.md
5    memory-compile-skill/SKILL.md
6    strategy-proposal-skill/SKILL.md
7    operator-diagnosis-skill/SKILL.md
8    human-review-precheck-skill/SKILL.md
9    planning-strategy-skill/SKILL.md
10   multi-agent-advisor-skill/SKILL.md
11   model-routing-skill/SKILL.md
12
13   agent_runtime/skills/
14     skill_registry.py
15     skill_loader.py
```

`skill_registry.py` 至少记录：

代码块

```
1  {"skill_id": "experiment-review-skill", "stage":
   "post_experiment_review", "required_inputs": ["experiment_summary",
   "branch_results", "effect_analysis", "memory_summary"], "forbidden_actions":
   ["modify_score", "modify_operator", "publish_active_memory"], "output_schema":
   "experiment_review_skill_output.schema.json"}
```

注册表只负责“什么时候加载哪个 Skill”。它不能授权越权工具，也不能绕过现有 policy。

5. P0 Skills

P0 Skills 先做，因为它们直接影响当前 Agent 外壳能否稳定复盘、报告和恢复。

5.1 `experiment-review-skill`

适用场景：实验结束后，需要复盘候选、分支、评分变化和失败原因。

输入材料：实验摘要、分支结果、候选统计、效果分析、局部 Memory 摘要、Agent 事件。

输出结构：

代码块

```
1  {"summary": "本次实验是否找到候选边界", "outcome_type": "score_decreased |
   score_increased | no_gain | not_applicable | validation_failed |
   mixed", "findings": [], "needs_human_review": [], "evidence_refs": []}
```

禁止事项：不能修改评分，不能认定自动评分候选为已确认边界，不能发布记忆。

验收标准：能区分业务失败和系统失败；每条结论都有证据引用；报告中能说明为什么需要人工复核。

5.2 agent-report-skill

适用场景：生成 `agent_report.md` 或多 Agent 复盘章节。

输入材料：AgentTask、AgentPlan、工具事件、观察摘要、决策记录、复盘建议。

输出结构：报告章节草案，包括目标、计划、执行结果、观察、风险、人工复核项和下一步建议。

禁止事项：不能写“已自动修复算子”“已发布 Memory”“已确认有效边界”。

验收标准：报告能被人工 reviewer 直接阅读；所有风险项有来源；自动结论和人工确认状态区分清楚。

5.3 recovery-diagnosis-skill

适用场景：运行失败、中断、产物缺失、manifest 异常、`score_increased` 或预算耗尽后，需要判断恢复路径。

输入材料：Agent 事件、工具返回结果、checkpoint、manifest、实验目录摘要、终止原因。

输出结构：

代码块

```
1  {"failure_type": "business_failure | system_failure | governance_block |
    unknown", "recommended_action": "resume | rollback | replan | stop_and_report |
    manual_review_required", "resume_point": "", "must_not_rerun":
    [], "evidence_refs": []}
```

禁止事项：不能在 `score_increased` 后同条件重复重跑；不能改变已冻结快照；不能跳过 manifest 校验。

验收标准：能说明为什么续跑、回滚或停止；恢复点明确；不能重跑的步骤明确。

6. P1 Skills

P1 Skills 用于把复盘结果沉淀为长期治理能力。

6.1 memory-compile-skill

适用场景：离线整理实验事实，生成策略卡草案或记忆候选。

输入材料：局部 Memory、失败记忆、无效生成记录、效果分析、分支结果、人工复核结果。

输出结构：候选事实、分类键、策略卡草案、冲突项、证据强度。

禁止事项：不能把单次实验事实直接写入 active；不能删除历史记忆；不能用没有来源的总结生成策略。

验收标准：每条候选事实保留来源实验、样本、轮次、分支、算子和评分证据。

6.2 strategy-proposal-skill

适用场景：Global Judge 或离线复盘需要把多条事实整理成 proposal、shadow 建议或人工复核项。

输入材料：策略卡草案、冲突审查、Replay/Holdout 结果、人工复核记录。

输出结构：proposed、shadow、needs_human_review 或 rejected_insufficient_evidence。

禁止事项：不能直接发布 active；不能自动修改 Router、Prompt、Rubric 或算子。

验收标准：建议状态和证据强度匹配；冲突未解决时只能进入人工复核。

6.3 operator-diagnosis-skill

适用场景：分析算子表现，判断失败来自适用条件、生成质量、样本不匹配还是校验过严。

输入材料：算子 ID、候选问题、父题、验证结果、评分变化、not_applicable 记录、无效生成记录。

输出结构：算子风险、适用条件问题、排除条件建议、需要人工复核的证据。

禁止事项：不能直接改算子 Prompt；不能因为单次失败禁用整个算子。

验收标准：能把“算子失败”和“样本不适合”分开说明。

6.4 human-review-precheck-skill

适用场景：候选边界需要人工复核前，先整理复核优先级和风险点。

输入材料：候选题、父题、参考材料、评分结果、校验结果、机制命中分析。

输出结构：候选排序、复核原因、可回答性风险、泄漏风险、机制命中情况。

禁止事项：不能替代人工确认；不能把预审结果写成最终结果。

验收标准：人工 reviewer 能按清单逐条复核，不需要重新翻完整日志。

7. P2 Skills

P2 Skills 在核心复盘和记忆治理稳定后实施。

7.1 planning-strategy-skill

适用场景：Planner 或 Replanner 需要选择单算子、多算子横向搜索、纵向叠加、只读复盘或恢复计划。

输入材料：AgentTask、context_pack_v2.task_context、预算、允许工具、memory_context Top-K 摘要、历史失败原因、dynamic_tail 中的当前 observation 摘要。

输出结构：推荐计划类型、预算建议、算子策略、停止条件、人工复核门槛。

禁止事项：不能绕过 Plan Validator；不能跳过真实评分；不能让 Memory 直接覆盖 Router 结果。

验收标准：计划能被现有 policy 校验；失败后能说明 replan 原因。

7.2 multi-agent-advisor-skill

适用场景：多 Agent 协作中，专项智能体需要读取证据包并输出 advice。

输入材料：advisor_spec_context、裁剪后的 evidence_pack_slice、允许工具、输出 schema、必要的 advisor_dynamic_instruction。

输出结构：统一 advice，包括 advisor_id、status、summary、findings、forbidden_actions_requested。

禁止事项：不能启动其它智能体；不能请求真实执行工具；不能写正式实验目录；不能要求读取完整父上下文或完整实验目录。

验收标准：越权建议被显式标记；没有证据的建议自动降级。

7.3 model-routing-skill

适用场景：派生子智能体时，需要根据任务类型选择模型能力层级。

输入材料：AdvisorSpec、任务风险、预算、上下文长度、evidence_pack_slice 大小和 hash、是否需要 JSON、是否需要证据引用。

输出结构：model_tier、fallback 层级、选择理由、禁止降级条件。

禁止事项：不能在子智能体中硬编码具体模型；不能让低成本模型完成策略归纳、冲突审查、评分稳定性或最终合成。

验收标准：搜索/摘录类任务可路由到低成本模型；归因/策略/合成类任务必须使用更高推理层级并记录路由结果。

8. 实施步骤

8.1 第一步：制定 P0 Skills

实现内容：编写 experiment-review-skill、agent-report-skill、recovery-diagnosis-skill。

验收标准：只读复盘、报告生成和失败恢复都有明确规程；报告不再出现确认状态混淆。

8.2 第二步：建立 Skill 注册和加载

实现内容：新增 Skill 注册表和加载器，支持按阶段加载对应 Skill。

验收标准：未注册 Skill 不能被调用；加载失败时 Agent 能降级为基础规则并写入事件。

8.3 第三步：制定 P1 Skills

实现内容：编写 `memory-compile-skill`、`strategy-proposal-skill`、`operator-diagnosis-skill`、`human-review-precheck-skill`。

验收标准：记忆候选、策略 proposal、算子诊断和人工复核预审都有统一输出结构。

8.4 第四步：制定 P2 Skills

实现内容：编写 `planning-strategy-skill`、`multi-agent-advisor-skill`、`model-routing-skill`。

验收标准：计划选择、多 Agent advice 和模型路由不再依赖临时提示词。

8.5 第五步：回归测试和文档联动

实现内容：为每个 Skill 准备最小样例输入和期望输出；把 Skill 使用方式写入相关阶段文档。

验收标准：后续实现人员可以用样例判断 Skill 是否被正确执行。

9. 必测场景

必须覆盖以下场景：

1. 自动评分候选进入报告时，不能被写成已人工确认。
2. `score_increased` 后，恢复建议不能同条件重复重跑。
3. 记忆编译不能把单次实验事实写入 active。
4. 策略 proposal 缺少证据引用时，必须进入 `rejected_insufficient_evidence` 或 `needs_human_review`。
5. 算子诊断不能因为单次 `not_applicable` 禁用整个算子。
6. 人工复核预审不能替代人工确认。
7. 多 Agent advice 请求真实执行工具时，必须被拒绝。
8. 模型路由不能把高风险合成任务降级到低成本摘录模型。
9. Skill 文件缺少输入、禁止事项或输出结构时，注册表检查必须失败。
10. Skill 加载失败时，Agent 必须写入事件并使用基础规则降级。
11. Skill 请求读取完整父上下文、完整实验目录、完整模型响应或全量 Memory 时，必须被注册表或 policy 拒绝。
12. Skill 输出缺少 `evidence_refs` 或 `artifact_refs` 时，不能进入报告、记忆或策略 proposal。

10. 最终验收标准

本阶段完成后，应满足：

1. P0、P1、P2 Skills 均有明确用途、输入、输出、禁止事项和验收标准。

2. Tool、Operator 和 Skill 的边界清晰，不会把业务算子误当成 Agent Skill。
3. Agent 在复盘、报告、恢复、记忆编译、策略 proposal、多 Agent advice 和模型路由时可以加载对应 Skill。
4. 所有 Skill 输出都能保留证据引用，并能被报告、记忆或人工复核链路消费。
5. Skill 不具备正式执行权，不能绕过 policy、schema、Plan Validator、发布门禁和人工复核。
6. Skill 输入和输出都能对齐 `context_pack_v2`、Memory 摘要和多 Agent 证据切片规则，不能退化为全量上下文提示词。

11. 暂不实施内容

以下内容不进入本阶段：

1. 给每个 O10-O33 算子单独制定 Agent Skill。
2. 用 Skill 替代正式工具、schema 校验或评分链路。
3. 让 Skill 自动修改正式 Prompt、Router、Rubric、算子或 active Memory。
4. 在没有注册表和测试样例的情况下让 Agent 动态生成临时 Skill。
5. 引入跨项目通用 Skill 市场或远程 Skill 自动安装。

这些内容会增加不可控行为，且不能直接提升当前项目的可恢复、可审计和可复盘能力。